Polar Derotation: Coupled-RoPE 언어 모델에서 3비트 KV 캐시 품질 절벽 돌파

AmesianX
독립 연구자
amesianx@gmail.com
https://powerhacker.net
https://github.com/AmesianX/TurboQuant

2026년 4월
작업 중인 초고 — 배포용 아님

Abstract

이 논문은 coupled-RoPE 언어 모델을 위한 새로운 KV 캐시 포맷 **TBQX3_1**을 소개한다. 이미 학습이 끝난 모델에 손을 대지 않고도 content 와 position 을 분리해서 저장하는 첫 구현이며, 두 가지 아이디어가 결합되어 있다.

첫째는 **Polar Derotation** 이다. K 를 양자화하기 전에 RoPE 회전을 미리 빼내서, 위치 정보가 제거된 content 만 쌍극좌표 $(r, \varphi^{\text{content}})$ 로 저장한다. 위치는 어텐션을 읽는 시점에 슬롯 인덱스로부터 대수적으로 다시 붙인다. 둘째는 **Tangent Residual** 이다. 3비트 uniform 위상 양자화기의 잔차 오차가 거의 전부 양자화된 위상의 접선 방향에 놓인다는 사실을 이용해, 페어당 1비트만으로 보정을 걸어준다. 보정의 크기 $r \cdot \pi/16$ 은 기하학적 상수이고, 방향 $(-\sin\hat{\varphi}, \cos\hat{\varphi})$ 는 디퀀트 때 이미 계산해둔 코사인/사인을 그대로 재활용한다.

두 기법을 합치면 3.625 bpw 에서 동작하는데, Qwen3-14B 40K 컨텍스트, temperature 0 환경의 35문항 수학 벤치에서 **f16 정확도를 넘어선다** (37.1% vs 34.3%). 동시에 KV 캐시는 4.74× 줄어들고 (6400 MiB → 1350 MiB), 디코드 속도는 기존 3비트 TBQ 와 사실상 동일하다. 같은 워크로드에서 기존 TBQ3_1 은 f16 보다 17% 낮게 나오는데, 이 격차가 바로 이 논문이 닫고자 하는 3비트 품질 절벽이다. Polar Derotation 이 겨냥하는 품질 지점은 Multi-head Latent Attention (MLA) [5] 이 아키텍처 재설계로 도달한 것과 같지만, 이미 학습된 coupled-RoPE 모델에 소급 적용 할 수 있다는 점이 결정적으로 다르다. 재학습도 필요 없고 가중치 포맷을 바꿀 필요도 없다. Llama, Qwen, Mistral, Gemma, Yi 같은 coupled-RoPE 계열 전체가 대상이다. 덤으로 무손실 컨텍스트 시프트 도 공짜로 따라온다. 본 연구는 3비트 영역에 한정된 개입이며, 4비트 구성은 범위 밖이다.

1 서론

1.1 왜 3비트인가, 왜 3비트만 다루는가

선행 연구 [4] 에서 우리는 llama.cpp 안에 TurboQuant [3] 을 프로덕션 수준으로 처음 구현해 Gemma 4 26B 에서 FP16 대비 6% perplexity 저하에 4.2× KV 압축을 달성했다. 요소당 3비트 구성이다 (K 는 2비트 Lloyd-Max + 1비트 QJL, V 는 MSE 만). 제품에 쓸 수는 있지만, Qwen3 같은 coupled-RoPE 모델에서는 토큰 단위 벤치마크에서 FP16 품질의 약 96% 정도만 따라간다.

이 격차를 보는 가장 자연스러운 반응은 "그냥 4비트로 올리지" 이지만, 우리는 그 길을 해법으로 치지 않는다. 4비트까지 올리면 대부분의 최신 양자화기는 — 심지어 본 논문의 어떤 기법도 없는 TBQ v1 조차도 — FP16 급 품질에 거의 다 도달한다. 4비트 영역에서는 Polar Derotation 도, PolarQuant 도, TurboQuant 도, 많은 경우 QJL 조차도 필요 없다. 해상도가 이미 충분해서 양자화 잡음이 모델 자신의 추론 마진 아래로 떨어져 버리기 때문이다. 연구적으로도 기여할 여지가 적고, 엔지니어링적으로는 더 분명하다. 4비트는 3비트 대비 저장 비용이 두 배 드는데, 그건 애초에 압축으로 피하려던 비용 그 자체다.

흥미로운 지점은 요소당 3비트다. 3비트 캐시는 4비트보다 풋프린트가 절반이라, 4비트로는 못 담는 장문맥 워크로드를 같은 메모리 예산 안에 밀어 넣을 수 있고, 엣지와 멀티테넌트 서빙을 현실적으로 만든다. 그런데 coupled-RoPE 모델에서는 4비트와 3비트 사이가 부드러운 저하가 아니라 **품질 절벽** 이다. 기존 방법들도, 우리 선행 TBQ v1 도 이 절벽에서 떨어졌고, Lloyd-Max 코드북을 아무리 튜닝하거나 QJL 잔차 균형을 만져도 다시 올라서지 못했다.

그래서 본 논문은 오직 3비트 영역만 다룬다. 4비트 수치는 보고하지 않고 4비트 개선도 주장하지 않는다. Polar Derotation 은 기존의 통계적 방법이 손을 들고 마는 바로 그 지점에서만 쓸모를 가지는 **3비트 개입** 이다. 우리가 던진 질문은 이거였다. 3비트 절벽이 3비트라는 해상도 자체의 본질적 한계인가, 아니면 우리 (그리고 선행 연구) 가 쓰지 않고 지나친 표현상의 중복성을 반영하는 것인가? 이 논문은 후자라고 주장한다.

이 논문의 핵심 축. 두 개의 기여가 전부다. 하나는 **coupled-RoPE 캐시 위에서의 Polar Derotation 실제 구현**, 다른 하나는 **Tangent Residual** 이다. 이 둘이 결합되어 3.625 bpw 에서 f16 수학 벤치를 이긴다.

1. **coupled-RoPE 에서 Polar Derotation 의 최초 end-to-end 구현** (§4, §5). 캐시 경계에서 위상으로부터 $p\omega_i$ 를 빼고, 콘텐츠 전용 쌍극좌표 $(r, \varphi^{\text{content}})$ 를 저장하고, 읽기 시점에 `__sincosf` 로 위치를 대수적으로 되돌리는 변환이다. MLA 가 아키텍처 재설계로 만들어내는 content/position

분리를 소급해서 재현하는 것이다. 재학습도 필요 없고, 가중치 포맷도, 토크나이저도 건드리지 않는다. 참조 구현은 llama.cpp 의 23개 파일을 수정하며, 모두 head_dim $= 128$ polar 경로에만 국한된다.

2. **크기 채널의 Rayleigh Lloyd-Max**(§4.4). 복소 가우시안 페어의 크기가 Rayleigh 분포를 따른다는 사실에서, σ 정규화 좌표계의 8-레벨 Lloyd-Max 코드북을 닫힌 형식으로 유도한다. 캘리브레이션 데이터도, 모델별 튜닝도 필요 없다. σ 추정도 Rayleigh 2차 모멘트로부터 $\hat{\sigma} = \sqrt{\sum r_i^2 / 2n}$ 로 바로 나온다.

3. **Tangent Residual: 해석적 1비트 위상 보정**(§4.5). 각도 양자화 오차를 $\pm\pi/8$ 에서 $\pm\pi/16$ 로 절반으로 줄이는 기하학적으로 정확한 보정이다. 비용은 페어당 정확히 1비트와 읽기 때의 FMA 두 번. 보정의 크기 $r \cdot \pi/16$ 는 기하 상수이고, 방향 $(-\sin\hat{\varphi}, \cos\hat{\varphi})$ 는 디퀀트가 이미 만들어둔 코사인/사인의 좌표 치환이다. 학습된 스케일도, 캘리브레이션도, 추가 삼각 함수 호출도 없다.

4. **3.625 bpw 로 수학 벤치에서 f16 을 이김**(§7). Qwen3-14B, 40K 컨텍스트, temperature 0, seed 1234 기준으로 TBQX3_1/TBQ3_1 이 $13/35$ (37.1%), f16/f16 이 $12/35$ (34.3%), 기존 TBQ3_1/TBQ3_1 이 $10/35$ (28.6%) 다. KV 캐시 풋프린트는 6400 MiB 에서 1350 MiB 로 (4.74×), 디코드 처리량은 21–22 tokens/s (f16 은 24–25).

5. **무손실 컨텍스트 시프트가 덤으로 나온다**(§4.7). 저장된 위상이 이미 위치에 독립이라 `build_rope_shift` 경로가 그냥 인덱스만 업데이트하는 상수 시간 연산으로 줄어든다. dequantize/rotate/requantize 왕복이 사라지고, 장문맥 슬라이딩 윈도우 서빙에서 기존 TBQ 가 가지고 있던 결함이 닫힌다.

6. **폐기된 변종들의 연구 로드맵**(§9). 실제로 구현하거나 진지하게 고려했다가 결국 버린 다섯 가지 대안 (TBQXP3_1 Direct Signs, TBQX2_1 2비트 사분면, WHT+polar 결합, 오프라인 φ 캘리브레이션, 셀별 적응형 FP32 fallback) 을 각자의 실패 이유와 함께 기록한다. 다음에 sub-4비트 coupled-RoPE KV 캐시를 건드릴 누군가의 설계 공간을 좁혀주기 위해서다.

이 논문이 주장하지 않는 것. 새로운 양자화 알고리즘을 내놓는 것이 아니다. Lloyd-Max, WHT 전처리, QJL 잔차 보정은 필요한 곳에서 그대로 쓰이며, Rayleigh Lloyd-Max 는 이미 알려진 분포에 표준 Lloyd-Max 를 닫힌 형식으로 특수화한 것뿐이다. 새 모델 아키텍처를 제안하는 것도 아니다. 그리고 TBQX3_1 이 모든 벤치, 모든 모델, 모든 seed 에서 f16 을 이긴다는 주장도 하지 않는다. 수학 벤치 결과는 방향성 자체는 재현 가능하지만 (테스트한 모든 seed 에서 f16 이상) 마진은 흔들리고, 특히 seed 52 에서는 무승부가 나왔다. 기여는 구조적인 것이다. coupled-RoPE 키 양자화를 content 와 position 이 대수적으로 분리 가능한 영역으로 옮겼고, 그 영역에서 잔여 위상 오차를 기하학적으로 정확한 1비트 보정으로 닫았다는 것.

2 배경

2.1 쌍별 복소 회전으로 본 RoPE

Rotary Position Embedding [1] 은 쿼리와 키의 각 쌍에 2D 회전을 적용해서 절대 위치를 인코딩한다. 헤드 차원 D (짝수)에서 키 $k \in \mathbb{R}^D$ 를 $D/2$ 개의 연속 쌍 (k_{2i}, k_{2i+1}) 로 나누고, 각 쌍에 다음 회전을 건다:

$$\begin{pmatrix} k'_{2i} \\ k'_{2i+1} \end{pmatrix} = \begin{pmatrix} \cos\theta_i & -\sin\theta_i \\ \sin\theta_i & \cos\theta_i \end{pmatrix} \begin{pmatrix} k_{2i} \\ k_{2i+1} \end{pmatrix}, \quad \theta_i = p \cdot \omega_i, \quad (1)$$

여기서 p 는 토큰 위치, $\omega_i = \text{base}^{-2i/D}$ 는 쌍별 주파수다 (표준 베이스는 10^4 또는 10^6).

여기서 중요한 관찰은, 식 (1) 이 복소 쌍 $k_i := k_{2i} + \imath k_{2i+1}$ 에 대한 복소 곱셈 $k'_i = k_i \cdot e^{\imath\theta_i}$ 와 수학적으로 완전히 같다는 것이다. RoPE 는 태생적으로 극좌표 구조인 대상에 쌍별로 위상만 더해주는 연산이다. 크기 $|k_i|$ 는 건드리지 않고 위상만 $p\omega_i$ 만큼 돌려준다.

2.2 Coupled RoPE 와 Decoupled RoPE

두 계열을 구분해둔다.

Coupled RoPE. 키 벡터 전체가 식 (1) 으로 회전된다. 모든 쌍의 위상에 content 와 position 이 한데 섞여 들어간다. Llama 2–4, Qwen2/2.5/3, Mistral, Gemma 1–4, Phi, Yi, Falcon — 현재 배포된 오픈 웨이트 LLM 의 거의 전부가 이쪽이다.

Decoupled RoPE. 키를 학습 시점에 $D = D_c + D_r$ 로 쪼갠다. D_c 는 RoPE 를 타지 않는 content 라텐트, D_r 은 RoPE 가 걸리는 작은 rope 성분 (보통 64 차원) 이다. DeepSeek-V2/V3 의 MLA [5] 와 GLM-4.5/4.6/4.7 이 이 구조를 쓴다. 선행 TBQ 연구에서 우리는 64 차원 rope 슬라이스를 FP16 패스스루 블록으로 저장했다. 이 영역의 norm 이 라텐트 norm 의 약 80배라 양자화하면 어텐션이 너무 심하게 망가지기 때문이다.

Decoupled 설계는 content 와 position 이 섞이는 문제에 대한 아키텍처 레벨의 해결책이다. 잘 작동하지만, 처음부터 그렇게 학습된 모델에만 해당된다.

2.3 Post-RoPE 캐시 저장 관례

`transformers`, vLLM, `llama.cpp`, SGLang, TensorRT-LLM 등 거의 모든 추론 엔진은 *post-RoPE* 키를 캐시에 담는다. 이는 아키텍처가 아니라 런타임 효율 때문의 선택이다. 매 디코드 스텝마다 RoPE 를 다시 돌리지 않기 위한 것이다. 결과적으로 coupled-RoPE 모델에서는 양자화되는 모든 원소가 content 와 position 을 섞어서 담고 있다는 뜻이 된다.

2.4 PolarQuant 과 TurboQuant

PolarQuant [2] 은 KV 캐시에 재귀적 쌍극좌표 변환을 처음 도입했다. 무작위 전처리 후 각도 주변 분포가 해석적으로 계산 가능해져서 블록당 scale/zero-point 메타데이터를 생략할 수 있다. TurboQuant [3] 은 여기에 1비트 QJL 편향 보정을 씌운 것이다.

PolarQuant 의 쌍 구조가 RoPE 의 쌍 구조와 일치하는 것은 순전히 우연이다. PolarQuant 자체는 RoPE 를 전혀 신경 쓰지 않고, 극 표현을 순전히 분포 정형화 용도로만 쓰며, 각도 φ_i 에는 위치 정보가 그대로 남아 있다. 본 논문의 Polar Derotation 은 같은 표현을 완전히 다른 목적 — 위치 중복성 제거 — 에 활용한다. 둘은 대체 관계가 아니라 겹쳐서 쓸 수 있는 합성 관계다.

3 위치 중복성 관찰

슬롯 p 에 있는 coupled-RoPE 캐시의 post-RoPE 복소 쌍을 $k'_i = r_i e^{\imath\varphi_i}$ 로 적자. 식 (1) 을 대입하면 다음과 같이 분해된다:

$$\varphi_i = \varphi_i^{\text{content}} + p \cdot \omega_i, \qquad r_i = r_i^{\text{content}}, \tag{2}$$

$(r_i^{\text{content}}, \varphi_i^{\text{content}})$ 는 모델 W_K 의 원시 출력, 즉 pre-RoPE 극좌표다.

여기서 세 가지 사실이 따라 나온다.

사실 1. 크기는 위치에 영향받지 않는다. RoPE 는 r_i 를 건드리지 않으니, 크기에 들어가는 양자화 비트는 오직 content 만 측정한다. 그런데 카테시안 양자화기에서는 이 속성이 눈에 안 들어온다. r_i 가 별도 좌표로 드러나지 않고 (k_{2i}, k_{2i+1}) 안에 얽혀 있어 위상 정보와 비트 예산을 같이 나눠 쓰기 때문이다.

사실 2. 위상에는 중복된 위치 정보가 들어 있다. $p \cdot \omega_i$ 항은 두 가지로 완전히 결정된다.

- p: 토큰 위치 — 캐시 슬롯 인덱스 바로 그 값이며, 어느 커널이든 이미 알고 있다.
- ω_i: $D/2$ 개짜리 상수 테이블 — 모든 레이어, 모든 헤드, 모든 요청이 공유한다.

결국 $\varphi_i = \varphi_i^{\text{content}} + p\omega_i$ 를 저장하는 것은 재구성 비용 0 인 정보를 정밀도 예산에 박아 넣는 것이다. 공짜로 얻을 수 있는 신호를 비싸게 사 쓰고 있는 셈이다.

사실 3. 3비트 절벽은 본질적 한계가 아니라 위치 중복성 절벽이다. FP16 에서는 content 와 position 이 관찰될 정도의 충돌 없이 잘 공존한다. 4비트에서도 섞임은 통계적으로는 별 문제가 안 된다. 원소당 남는 해상도가 두 신호를 품질 임계치 아래에서 흡수할 만큼 여전히 넉넉하다. 4비트 KV 캐시가 거의 모든 양자화기에서 "그냥 작동" 하는 이유가 이것이다. 3비트로 내려가면 상황이 갑자기 바뀐다. 해상도가 신호 자체의 정보량과 비슷한 수준이 되고, 중복된 위치에 쓰인 비트는 전부 content 에서 떼어낸 비트가 된다. 우리가 (그리고 우리가 아는 모든 sub-4-bit KV 양자화기가) coupled-RoPE 모델에서 본 3비트 품질 절벽은 따라서 3비트라는 해상도의 본질적 한계가 아니라, 위치 중복성이 처음으로 품질을 결정하는 제약이 되는 특정 영역일 뿐이다. 이 절벽을 닫으려고 굳이 4비트로 올라갈 필요는 없고 (그럼 압축하는 의미가 없다), 3비트 영역 안에서 중복성을 제거하면 된다. Polar Derotation 이 하는 일이 정확히 그것이다.

4 방법: Polar Derotation

4.1 알고리즘

캐시 쓰기 (위치 p 의 토큰).

1. 어텐션 프로젝션으로부터 post-RoPE 쌍 $k'_i = (k'_{2i}, k'_{2i+1})$ 을 받는다.
2. 극좌표로 바꾼다: $r_i = \sqrt{(k'_{2i})^2 + (k'_{2i+1})^2}$, $\varphi_i = \text{atan2}(k'_{2i+1}, k'_{2i})$.
3. **Derotate**: $\varphi_i^{\text{content}} \leftarrow (\varphi_i - p\omega_i) \bmod 2\pi$.
4. $(r_i, \varphi_i^{\text{content}})$ 를 기존 양자화 방식 (TBQ 3비트 Lloyd-Max, PolarQuant 스타일 등) 중 하나로 양자화한다.

어텐션 읽기 (쿼리 p_q 가 캐시 슬롯 p_k 에 접근).

1. $(\hat{r}_k, \hat{\varphi}_k^{\text{content}})$ 를 역양자화한다.
2. **Rerotate**: $\hat{\varphi}_k \leftarrow \hat{\varphi}_k^{\text{content}} + p_k\omega_i$.
3. 카테시안으로 복원하여 ($\hat{k}_i = \hat{r}_k\, e^{\imath\hat{\varphi}_k}$) 기존 `vec_dot` 을 재사용하거나, 극 공간에서 직접 내적을 계산한다:

$$\langle q_i, \hat{k}_i \rangle = r_{q,i} \cdot \hat{r}_k \cdot \cos(\varphi_{q,i} - \hat{\varphi}_k). \tag{3}$$

4.2 위치 채널이 정확한 이유

Derotation 과 rerotation 은 대수적으로 서로의 역이다. 부동소수점에서도 같은 ω_i (FP32 상수 테이블) 와 같은 정수 p (캐시 슬롯 인덱스) 를 쓰기 때문에 비트 동일한 결과로 왕복할 수 있다. 위치 채널은 새로운 오차를 더하지 않는다.

유일한 오차 경로는 $(r_i, \varphi_i^{\text{content}})$ 의 양자화뿐이다. 그리고 같은 비트 예산이라는 조건에서 이 오차가 (k_{2i}, k_{2i+1}) 에 대한 카테시안 기준선 오차보다 반드시 작다는 것이 다음 소절의 주장이다.

4.3 content 분포가 더 좁은 이유

표준 인덱싱에서 i 가 큰 고주파 쌍은 긴 컨텍스트에 걸쳐 $p\omega_i$ 가 여러 바퀴 돌아간다. 블록 안의 토큰들을 모아놓고 보면 φ_i 는 $[0, 2\pi)$ 상의 균등분포 — 즉 최대 엔트로피 — 에 가까워진다. 모델 W_K 가 무엇을 내놓았든 상관없이 그렇다. 이런 주변 분포에 맞춘 Lloyd-Max 양자화기는 결국 균등 섹터 분할보다 잘할 수가 없다.

반대로 content 전용 위상 $\varphi_i^{\text{content}}$ 는 모델 프로젝션의 학습된 구조만 반영하고 위치 잡음이 빠진다. 경험적으로는 이 분포가 훨씬 몰려 있을 것으로 예상되며 (Phase 1 측정 대기, §7 참조), 그 결과 같은 8 섹터 (3비트 위상) 가 content 관련 차이를 훨씬 더 정밀하게 해상한다. 프로덕션 coupled-RoPE 모델의 고주파 쌍에서 집중도가 적어도 3× 정도 올라갈 것으로 보고, 이것을 첫 경험적 산출물로 삼는다.

4.4 크기 채널의 Rayleigh Lloyd-Max

Derotate 이후 페어 (k_x, k_y) 는 위치와 무관한 content 를 담는다. W_K 프로젝션이 근사적으로 등방 가우시안 페어 활성화를

내놓는 모델에서, 크기 $r = \sqrt{k_x^2 + k_y^2}$ 는 해석적으로 Rayleigh 분포를 따른다:

$$p(r;\sigma) = \frac{r}{\sigma^2}\exp\left(-\frac{r^2}{2\sigma^2}\right), \tag{4}$$

2차 모멘트는 $E[r^2] = 2\sigma^2$ 이다. 여기서 바로 캘리브레이션 없이 쓸 수 있는 스케일 추정이 나온다. n 개 페어를 가진 임의의 블록에 대해

$$\hat{\sigma} = \sqrt{\frac{1}{2n}\sum_{i=1}^{n} r_i^2}. \tag{5}$$

더 중요한 건, Rayleigh 분포가 σ 정규화 좌표계에서 **모델이나 데이터셋에 무관한 닫힌 형식의 8-레벨 Lloyd-Max 코드북**을 허용한다는 점이다. Rayleigh pdf 위에서 표준 Lloyd-Max 반복을 수치적으로 풀면 다음 경계 **b** 와 센트로이드 **c** 가 나온다:

$$\begin{aligned}\mathbf{b}/\sigma &= \big(0.4280,\ 0.7848,\ 1.0991,\ 1.4101,\\ &\qquad 1.7268,\ 2.0623,\ 2.4427\big),\\ \mathbf{c}/\sigma &= \big(0.2400,\ 0.6160,\ 0.9420,\ 1.2547,\\ &\qquad 1.5685,\ 1.8946,\ 2.2520,\ 2.6650\big).\end{aligned} \tag{6}$$

저장 비용은 페어당 3비트에 σ 용 `half` 하나가 전부다. 블록별 히스토그램도, 학습 시점 캘리브레이션도, 모델별 튜닝도 없다. 같은 상수가 어떤 coupled-RoPE 모델의 어떤 레이어, 어떤 블록에도 그대로 적용된다. 이 분포가 데이터셋 특성이 아니라 W_K 의 WHT 혹은 가우시안 프로젝션 통계에서 나오기 때문이다. 일반 k-평균 양자화와는 질적으로 다른 상황이며, TBQX 가 3.125 bpw 에서 품질 여유를 확보하는 두 이유 중 하나다.

4.5 Tangent Residual: 해석적 반 셀 보정

두 번째 이유는 Rayleigh Lloyd-Max 로 크기를 먼저 잡은 뒤에 남는 잔차 오차가 어느 방향 에 놓이는지에 대한 구조적 관찰이다.

$[-\pi, \pi)$ 를 uniform 3비트로 자르면 셀 폭은 $\pi/4$ 가 되고, 잔차 각도 오차는 $|\Delta\varphi| \le \pi/8 \approx 22.5^\circ$ 로 제한된다. 이것만 해도 카테시안 복원 오차로 치면 꽤 크다. 페어당 오차가

$$|K_{\text{actual}} - K_{\text{polar}}| \approx r\,|\Delta\varphi| \tag{7}$$

로 r 에 비례하기 때문이다. 경험적으로 이 영역이 바로 저확률 토큰 drift 가 나오는 지점이다. Temperature 0 에서 희소 transliteration 토큰 (예: 서구 과학자 이름의 한국어 표기) 이 인접한 문자집합 클러스터로 flip 되는 현상이 그 예인데, top-1 logit 의 여유가 $\pm\pi/8$ 셀이 만드는 attention score 교란보다 좁기 때문에 흔들리는 것이다.

해결의 실마리는, $\Delta\varphi$ 가 작을 때 잔차가 거의 전부 양자화된 위상 $\hat{\varphi}$ 에서의 constant-r 원의 **접선** 방향에 놓인다는 사실이다. 카테시안 평면으로 풀어 쓰면 다음과 같다:

$$K_{\text{actual}} - K_{\text{polar}} \;\approx\; r\,\Delta\varphi\,\big(-\sin\hat{\varphi},\ \cos\hat{\varphi}\big) + O(\Delta\varphi^2). \tag{8}$$

그러면 두 가지 관찰이 이걸 값싼 보정으로 만들어준다.

- **보정의 크기는 해석적으로 결정된다.** 반폭 $\pi/8$ 인 3비트 uniform 셀에서 센트로이드로부터의 평균 반 셀 오프셋은 $\pi/16$ 이다. 학습해서 얻는 스케일이 아니라 순수 기하 상수이며, 블록별 메타데이터도 필요 없다.
- **방향은 공짜로 나온다.** 디퀀트 경로는 양자화된 페어를 복원하기 위해 이미 $(\cos\hat{\varphi}, \sin\hat{\varphi})$ 를 계산해둔다. 접선 방향 $(-\sin\hat{\varphi}, \cos\hat{\varphi})$ 는 좌표 치환과 부호 뒤집기 하나면 나온다. 추가 삼각 함수 호출은 전혀 없다.

그래서 Tangent Residual 보정은 블록 레이아웃에 정확히 **페어당 1비트** 만 더 얹고, 다음과 같이 복원을 다듬는다:

$$\begin{aligned}K_{\text{refined}} &= K_{\text{polar}}\\ &\quad + s\cdot r\cdot \tfrac{\pi}{16}\cdot(-\sin\hat{\varphi},\ \cos\hat{\varphi}),\end{aligned} \tag{9}$$

$s \in \{-1, +1\}$ 이고, 3비트 각도 셀 안에서의 $\Delta\varphi$ 부호가 이 한 비트에 들어간다. 읽기 쪽 전체 오버헤드는 FMA 두 개가 전부다. 유효 각도 해상도는 $\pm\pi/8$ 에서 $\pm\pi/16$ 으로 두 배 좋아지고 ($22.5^\circ \to 11.25^\circ$), 이는 단 1비트 비용으로 4비트 uniform 위상 양자화기와 등가인 것과 같다.

경험적으로도 (§7) Tangent Residual 은 Qwen3-14B 에서 관찰된 저확률 토큰 drift 를 없앤다. Wolfgang Pauli, Erwin Schrödinger 같은 희소 이름을 한국어로 물으면 나타나던 키릴 문자 오염이 temperature 0 에서 완전히 사라지고, 수학 추론 정확도는 유지되거나 오히려 조금 나아진다. 본 논문의 설계 언어로 말하면, *Rayleigh Lloyd-Max* 는 크기 쪽을 담당하고, *Tangent Residual* 은 접선 방향에 남는 호 길이 오차를 담당한다. 둘을 합치면 매우 작은 비트 비용으로 페어당 오차 예산을 거의 포화시킨다.

이렇게 조합된 스킴 — polar derotation, r 의 Rayleigh Lloyd-Max, φ^{content} 의 3비트 uniform 분할, 그리고 1비트 접선 부호 — 이 TBQ v2 참조 코드에 구현된 **TBQX3_1** 변종이다. 블록 포맷과 경험 수치는 각각 §5 과 §7 에 있다.

4.6 쌍별 비트 할당의 이종화

주파수 ω_i 는 자릿수 차이 (비율이 base 수준, 즉 10^4 나 10^6) 로 퍼져 있다. 저주파 쌍은 $p\omega_i$ 가 컨텍스트 안에서 거의 상수라 위치 섞임을 거의 보지 않고, content 분포 $(r, \varphi^{\text{content}})$ 는 크기가 지배적이고 위상은 압축된 모양이 된다. 고주파 쌍은 앞에서 말한 균등화된 위상을 그대로 만나며, derotation 으로 얻는 이득이 가장 크다.

Polar Derotation 은 이런 구조를 쌍당 두 개의 명시적 좌표로 드러내 주기 때문에, 카테시안 공간에서는 원리적으로 불가능했던 쌍별 비트 할당이 가능해진다. 3비트 평균을 유지한 예시 구성은 다음과 같다:

- 저주파 쌍: r 에 4비트, φ^{content} 에 2비트
- 고주파 쌍: r 에 2비트, φ^{content} 에 4비트
- 평균 원소당 3비트, TBQ v1 예산과 일치

최적 배분은 가중치 양자화기의 채널별 스케일 보정과 비슷하게, 활성화값을 보고 오프라인에서 정할 수 있다.

4.7 무손실 컨텍스트 시프트가 덤으로 나온다

서빙 운영 측면에서 독립적으로 가치 있는 부수 효과가 하나 있다. Coupled-RoPE 모델에서 컨텍스트 시프트 (슬라이딩 윈도우 KV 축출 + 재인덱싱) 는 개념적으로 저장된 모든 키를 새 위치로 다시 회전시켜야 한다. 양자화된 캐시에서는 요소마다 dequantize/rotate/requantize 왕복이 필요하다는 뜻이다. 현재 TBQ 구현은 그 비용을 피하기 위해 `build_rope_shift`

에서 early-return 을 걸어 두고 있는데, 대신 시프트된 토큰의 품질 저하를 감수하는 구조다.

Polar Derotation 을 쓰면 저장된 content 전용 위상 $\varphi_i^{\text{content}}$ 가 이미 슬롯-위치 매핑과 무관하다. 토큰을 슬롯 p 에서 p' 로 옮기는 것은 인덱스만 업데이트하면 끝이고, 다음 읽기는 같은 저장된 content 에서 $p\omega_i$ 대신 $p'\omega_i$ 를 계산해 올바른 post-RoPE 값을 복원한다. 커널 수준의 시프트 연산도, 품질 손실도 없다.

주 변환의 부수 효과로 TBQ v1 의 미해결 결함 하나가 같이 닫히는 셈이다.

5 TBQ v2 구현 계획

5.1 블록 레이아웃 (TBQX3_1)

참조 구현은 `block_tbqx3_1` 이다. $D = 128$ (64 페어) 기준 58바이트 레이아웃으로, §4 에서 도입한 세 채널 — polar 크기, content 위상, 1비트 접선 보정 부호 — 를 담는다.

```
block_tbqx3_1  (58 B, 3.625 bpw)
  d_r    half       2   // Rayleigh sigma
  qr     uint8[24] 24   // 3-bit r x 64
  qphi   uint8[24] 24   // 3-bit phi x 64
  qtan   uint8[8]   8   // 1-bit sign x 64
```

페어당 저장을 풀어보면 r 에 3비트, φ^{content} 에 3비트, 접선 부호에 1비트, 합쳐서 7비트다. 페어의 스칼라 원소 두 개로 평균내면 3.5 bpw 이고, 여기에 `half` 스케일 필드를 블록의 128 원소에 분할해 더하면 총 **3.625** bpw 가 된다.

이 레이아웃은 원본 `block_tbqp3_1` 에 있던 QJL 보정 비트를 의도적으로 뺐다. Derotate 된 content 에서는 QJL 스타일 랜덤 프로젝션이 pair-polar 표현과 잘 맞물리지 않는데 (QJL 은 WHT 로 전처리된 벡터 위에서 동작하는데, WHT 가 페어 구조를 깨기 때문이다), 경험 결과 (§7) 를 보면 Rayleigh Lloyd-Max 와 Tangent Residual 만으로 QJL 없이도 품질 격차가 닫힌다.

§4.6 의 이종 비트 할당을 지원하는 대체 레이아웃도 페어 그룹별로 r/φ 비트를 재분배해서 같은 바이트 예산 안에 넣을 수 있다. 위에 보인 기본 TBQX3_1 레이아웃이 §7 전반에서 쓰인 구성이다.

5.2 코드 지점

기존 TBQ v1 코드베이스 [4] 와의 통합은 두 파일에 국한된다.

- `ggml/src/ggml-cuda/cpy-utils.cuh` — `quantize_f32_tbqp3_1_block` 을 극 변형으로 교체. 캐시 슬롯 인덱스를 커널 파라미터로 받아 쌍별로 $p\omega_i$ 를 빼 $\varphi_i^{\text{content}}$ 를 만든 뒤, 기존 Lloyd-Max 인프라로 $(r, \varphi^{\text{content}})$ 를 양자화한다.
- `ggml/src/ggml-cuda/fattn-common.cuh` — `vec_dot_fattn_vec_KQ_tbqp3_1` 을 극 내적 경로로 교체. 두 가지 구현이 가능하다: (a) `__sincosf` 로 카테시안 복원 후 기존 내적 재사용, (b) 식 (3) 대로 극 공간에서 바로 내적을 계산하면서 코사인을 누산기에 녹이는 방식.

모델 가중치 파일, 토크나이저, GGUF 포맷, 캐시 외 경로는 건드리지 않는다. RoPE 자체를 끄거나 바꾸지도 않는다. 우리가 하는 일은 post-RoPE K 텐서가 양자화되는 경계에서 가로채는 것뿐이다.

5.3 지연 시간 예상

TBQ `fattn-vec` 커널은 RTX 6000 Ada, H100, GB200 급 하드웨어에서 메모리 바운드다 [4]. 쌍당 곱셈 한 번 $(p \cdot \omega_i)$, FMA 한 번 (위상 합산), `__sincosf` 한 번을 추가하는 정도는 HBM 지연 시간의 그림자 안에 전부 들어가고, 측정 가능한 처리량 감소는 없을 것으로 예상된다. 오히려 역양자화 경로가 교체되는 카테시안 WHT 역변환 경로보다 더 저렴 해질 수도 있다. 극 디코드는 쌍당 스칼라 조회 두 번과 삼각 평가 한 번뿐이고, 버터플라이 네트워크도 없기 때문이다.

5.4 정밀도 고려사항

긴 컨텍스트에서는 $p\omega_i$ 가 범위 축소 단계에서 정확도를 잃을 만한 크기에 이를 수 있다. 표준적인 완화 방법이 있다:

- φ^{content} 를 이미 $[0, 2\pi)$ 로 줄여 저장.
- $p\omega_i \bmod 2\pi$ 를 Payne-Hanek 범위 축소 [9] 로 FP32 에서 미리 계산해 컨텍스트 스텝마다 캐시.
- 극단적인 컨텍스트 $(p > 10^6)$ 에서는 약간의 지연 시간을 감수하고 `sincosf` 로 폴백.

셋 다 양자화 오차 분석에는 영향을 주지 않는다. 삼각 평가 자체의 오차만 제한할 뿐이다.

5.5 WHT 와의 상호작용

TBQ v1 은 주변 분포를 가우시안화하려고 Lloyd-Max 앞에 Walsh-Hadamard 전처리를 적용한다. 그런데 WHT 는 쌍 경계를 가로지르며 섞이는 연산이라, Polar Derotation 이 의존하는 극 구조를 깨뜨린다. 그래서 TBQ v2 는 셋 중 하나를 골라야 한다:

- **WHT 완전 제거.** Derotation 자체가 이미 content 분포를 충분히 다듬어주므로 추가 전처리가 필요 없을 수 있다.
- **쌍 내부 2×2 화이트닝.** 각 쌍 내부에만 고정 회전을 WHT 대신 걸어서 쌍 경계는 건드리지 않는다.
- **쌍별 독립 화이트닝.** 쌍마다 작은 화이트닝 회전을 오프라인으로 보정해 둔다.

어느 쪽이 옳은지는 경험적인 문제이고, Phase 2 에서 결정한다.

6 선행 연구와의 관계

6.1 PolarQuant 과 TurboQuant

PolarQuant [2] 은 KV 캐시에 쌍극 표현을 도입한 첫 사례지만 목적이 다르다. 무작위 전처리 후 각도 주변 분포가 해석적 형태를 가져서 블록당 scale 메타데이터를 없앨 수 있게 해주는 것이 주된 가치였다. PolarQuant 의 쌍 구조가 RoPE 의 쌍 구조와 일치하는 건 우연이다. RoPE 주파수 테이블 ω_i 나 슬롯 인덱스 p 는 전혀 쓰지 않는다.

Polar Derotation 은 PolarQuant 와 보완적이다. 알려진 위치 회전을 추가로 각도 좌표에서 빼내어, PolarQuant 이 쓰지 않고 버려두었던 모델 수준의 구조적 속성을 활용한다. 둘은 자연스럽게 합쳐진다. 분포 정형화를 위해 PolarQuant 의 전처리를 걸고, 그 위에 content 격리를 위해 derotate 하면 된다. TurboQuant 의 QJL 잔차 보정 [3] 도 수정 없이 그대로 둘러쌀

수 있고, 1비트 예산이 위치·콘텐츠 혼합 대신 content 전용 잔차 위에서 동작하게 되면 오히려 더 효과적일 것으로 기대된다.

6.2 Multi-head Latent Attention

DeepSeek-V2 [5] 와 그 후손들 (GLM-4.5/4.6/4.7) 은 위치·콘텐츠 얽힘을 아키텍처 수준에서 풀었다. $K = \mathrm{concat}(\mathrm{latent}_{D_c}, \mathrm{rope}_{D_r})$ 로 두고 RoPE 를 D_r 슬라이스에만 적용한다. Polar Derotation 과 결과적으로 같은 비트 효율 개선을 얻지만, 새 아키텍처로 학습된 모델에서만 성립한다.

Polar Derotation 은 일종의 **소급 MLA** 로 볼 수 있다. 이미 학습된 coupled-RoPE 모델에, 재학습 없이 가중치 수정 없이 같은 content/position 분리를 만들어준다. 적용 가능한 표면은 본질적으로 MLA 계열이 아닌 거의 모든 배포 오픈 웨이트 LLM 이며, 배포 건수로는 MLA 계열보다 여러 자릿수 많다.

6.3 카테시안 KV 양자화

KIVI [6], KVQuant [7], SmoothQuant-KV [8] 는 저장된 불투명한 텐서 위에서 카테시안 공간으로 동작한다. 이들은 위치 중복성을 활용할 수 없다. 중복성은 쌍 분해와 RoPE 주파수 테이블 ω_i 를 명시적으로 드러낸 뒤에야 구조적으로 보이기 때문이다.

7 평가

이 섹션의 모든 수치는 NVIDIA DGX Spark (GB10 SoC, 128 GB 통합 메모리), CUDA 12.8 에서 얻었고, 열 안정화 envelope (§9) 하에서 동작했다. 모델은 Qwen3-14B (Q4_K_M 가중치 양자화), 컨텍스트 길이 40,960, 디코드 예산 4,096, 샘플링은 temperature 0 이다.

7.1 메모리 풋프린트

ctx $= 40{,}960$, 40 layer 에서 llama.cpp 할당자가 보고하는 end-to-end KV 캐시 버퍼 크기는 다음과 같다.

7.2 디코드 처리량

7.3 수학 추론

수학 벤치는 세 계층의 35 문제로 구성된다 (2×2 행렬곱, 3×3 행렬곱, 스칼라 산술 체인). 답은 정수값이라 temperature 0 환경에서는 부분 점수가 있을 수 없다. 중간 토큰 하나가 잘못된 숫자로 flip 되면 그 문제는 전체가 실패한다.

여러 seed (42, 43, 52, 666, 1234) 에서 추가로 돌려본 결과도 같은 순서를 확인해준다. TBQX3_1 은 모든 seed 에서 f16 이상이고, 기존 TBQ3_1 이상이다. 실행에 따라서는 TBQX3_1 이 f16 을 더 큰 폭으로 앞서기도 한다 (seed 42 에서 $17/35$ vs $11/35$, $+55\%$). Seed 52 에서는 f16 과 무승부가 나왔다. 테스트한 seed 들에서 f16 대비 평균 향상은 약 $+20\%$, 기존 TBQ3_1 대비는 약 $+35\%$ 정도다. 이 수치들이 모두 temperature 0 에서 정확 일치 기준으로 나온 것이라는 점은 강조해둘 만하다. 더 높은 온도나 다른 벤치 세트에서의 평균 성능에 대해서는 추가 데이터 없이 주장하지 않는다.

7.4 희소 토큰 drift (정성적 관찰)

Tangent Residual 의 원래 동기는, 접선 보정 없는 legacy polar (3비트 uniform φ^{content}) 가 희소 토큰 질의에서 특징적인 출력 drift 를 만든다는 관찰이었다. Temperature 0 에서 "Wolfgang Pauli 의 한국어 음역이 뭐냐" 고 물으면, 깨끗한 한글 대신 키릴 문자가 섞인 이상한 문자열 (와 프강 폴리, 여기서 은 키릴의 "ol") 이 나왔다. 같은 질문을 f16/f16 에 주어도 올바른 음역은 안 나온다 (Qwen3-14B 가 이걸 안정적으로 알지 못한다). 다만 f16 은 깨끗한 한국어 실패 (바울리) 로 빠지지, 문자집합을 가로지르는 실패는 아니다.

Tangent Residual 을 켠 TBQX3_1 은 같은 질의에서 깨끗한 한국어 전용 출력을 낸다. Pauli 는 와인하르트 폴리 로, Schrödinger 는 에르빈 슈딩거 로 나온다. 모델이 정답을 몰라서 생기는 사실 오류는 그대로 남지만 — Qwen3-14B 는 여전히 올바른 음역을 모른다 — 문자집합 오염은 사라진다. 이게 바로 Tangent Residual 이 설계 단계에서 잡고자 했던 drift 현상이고, §4.5 의 기하학적 논증을 경험적으로 뒷받침해 준다. φ 오차를 $\pm\pi/8$ 에서 $\pm\pi/16$ 로 반으로 줄이면, 이런 류의 질의에서 attention score 교란이 top-1 이 flip 되는 임계 아래로 내려간다.

7.5 Qwen3-14B 외 커버리지

TBQX3_1 은 coupled RoPE 의 head_dim $= 128$ 구성에 한정되며, 이 구성이 Llama, Mistral, Qwen, Yi 계열 전체에서 지배적이다. head_dim $= 64$ 모델 (GPT-OSS 120B) 은 무관한 double-WHT-per-head 경로 [4] 를 쓰고, decoupled-RoPE MLA 모델 (DeepSeek-V2, GLM-4.7) 은 아키텍처 차원에서 이미 content/position 을 분리해 두어 derotation 이 필요 없다 (§6). 이런 구성에서 TBQX3_1 은 자신을 강요하지 않고 기존 특수 경로로 자연스럽게 빠진다. Fallthrough 동작에 대한 커버리지 테스트는 진행 중이다.

8 한계와 열린 문제

주파수 의존적 이득. 품질 개선의 폭은 고주파 쌍에서 가장 크다. $p\omega_i$ 가 천천히 변하는 저주파 쌍은 이미 content 가 지배적이라 얻는 이득이 제한적이다. 주파수 대 이득 곡선의 정량화는 Phase 1 산출물이다.

WHT 호환성. §5 에서 말했듯 TBQ v1 의 양자화 전 Walsh-Hadamard 변환은 쌍 단위에서 Polar Derotation 과 양립하지 않는다. Derotation 만으로 충분한지, 아니면 쌍 내부 화이트너가 필요한지는 경험적 문제로 남아 있다.

긴 컨텍스트에서의 삼각 정밀도. 위치가 약 10^5 를 넘고 ω_i 가 클 때 단순한 `__sincosf` 는 범위 축소 과정에서 정확도를 잃는다. 표준 구제책이 있기는 하지만, 잔여 오차가 양자화 오차 예산보다 훨씬 작다는 것을 따로 검증해야 한다.

QJL 재보정. TBQ v1 의 1비트 QJL 보정은 카테시안 잔차에 맞춰져 있다. Polar Derotation 하에서는 잔차 분포 자체가 (content 전용의 더 깨끗한 형태로) 달라지므로 QJL 부호 테이블을 다시 맞춰야 한다. 효과는 긍정적일 것으로 보지만 확인은 필요하다.

Config	K buffer	V buffer	Total	Compression
f16/f16	3200 MiB	3200 MiB	6400 MiB	1.00×
tbqx3/tbq3 (ours)	**725 MiB**	625 MiB	**1350 MiB**	4.74×
tbq3/tbq3 (TBQ v1)	625 MiB	625 MiB	1250 MiB	5.12×

Table 1: ctx $= 40{,}960$ 에서의 KV 캐시 버퍼 크기. TBQX3_1 은 Tangent Residual 비용으로 TBQ3_1 대비 K 쪽에 $+100$ MiB 프리미엄을 낸다. 총합은 순수 3비트 기준선의 8% 이내, 이론 상한 $5.3\times$ 의 21% 이내에 머문다.

Config	tokens/s	vs f16
f16/f16	24–25	1.00×
tbqx3/tbq3	**21–22**	0.87×
tbq3/tbq3	21–22	0.87×

Table 2: Qwen3-14B 디코드 처리량. TBQX3_1 은 Tangent Residual 보정이 추가되었는데도 TBQ3_1 대비 측정 가능한 감속이 없다. 페어당 FMA 두 개가 기존 HBM 지연 시간 그림자 안에 그대로 들어가기 때문이다. f16 대비 13% 격차는 derotation 고유의 비용이 아니라 TBQ vec 경로의 일반적인 비용이다.

RoPE 외 일반화. 이 방법은 RoPE 의 쌍별 회전 구조를 구체적으로 활용한다. ALiBi, T5 상대 위치, 절대 사인파 인코딩은 이 구조를 공유하지 않으므로 Polar Derotation 의 영향을 받지 않는다.

MLA 는 대상이 아니다. Decoupled RoPE (MLA, GLM-4.7) 모델은 위치/콘텐츠 분리가 이미 아키텍처에 녹아 있다. Polar Derotation 은 거기서 추가 이득을 제공하지 않으므로 우회되어야 한다. 기존 FP16 rope 패스스루는 그대로 두는 것이 맞다.

9 연구 로드맵: 막다른 길과 교훈

이 섹션은 TBQX3_1 을 만드는 동안 실제로 구현하거나 진지하게 고려했다가 결국 버린 변종과 방향들을 기록한다. 성공한 경로는 짧지만 실패의 표면은 넓다. 각 대안이 왜 실패했는지 구체적으로 남겨두는 이유는, 다음에 sub-4비트 coupled-RoPE KV 캐시를 건드릴 누군가의 설계 공간을 좁혀주기 위해서다.

9.1 TBQXP3_1: Direct Signs 잔차 보정 (4.25 bpw)

3비트 polar 품질 격차에 대한 첫 시도는 원본 QJL 문헌의 Direct Signs 잔차 기법을 그대로 이식한 것이었다. Rayleigh Lloyd-Max 로 r 을 복원하고 3비트 uniform 으로 φ^{content} 를 복원한 뒤, 페어당 카테시안 잔차

$$\mathbf{e}_i = (k_{x,i}, k_{y,i}) - r_i(\cos\hat{\varphi}_i, \sin\hat{\varphi}_i)$$

를 두 부호 비트 $(\text{sign}(e_x), \text{sign}(e_y))$ 와 공유 크기 스케일 d_{direct} (half 저장) 로 압축했다. 총 비용은 페어당 2비트에 블록 스케일 2 B 를 더해 $= 68$ B/블록 $= 4.25$ bpw 였다.

폐기한 이유. 독립적인 두 이유가 있었다. 첫째, 기준선 대비 1.125 bpw 의 오버헤드가 품질 이득에 비해 비쌌다. 나중에 Tangent Residual 로 3.625 bpw 에서 같은 (혹은 더 나은) 품질을 얻었다. 둘째, 이것이 더 근본적인데, Direct Signs 는 잔차를 비구조적으로 취급 한다. 암묵적으로 $\mathbf{e}_i$ 를 일반 2D 벡터로 모델링하고 비트 예산을 반경과 접선 성분 양쪽에 나눠 쓴다. 그런데 Rayleigh Lloyd-Max 뒤의 잔차는 비구조적이 아니다. 반경 성분 Δr 은 (크기 코드북이 거의 최적이라) 이미 작고, 잔차 에너지의 거의 전부가 접선 방향에 몰려 있다. Direct Signs 는 이미 잔차가 사라진 방향인 반경 쪽에 비트의 절반을 버리고 있었던 셈이다. Tangent Residual (§4.5) 은 이 기하학적 관찰을 활용해 같은 보정 품질을 2비트 대신 1비트로 뽑아내고, empirical d_{direct} 대신 완전한 해석적 크기를 쓴다.

교훈은 이렇다. **최적에 가까운 양자화기의 잔차는 아무 방향이나 향할 수 있는 벡터가 아니다.** 잔차의 분포는 양자화기 자체에 의해 형성되며, 이 구조를 무시한 보정 스킴은 비트를 과지불하게 된다.

9.2 TBQX2_1: 2비트 사분면 각도 (2.625 bpw)

정반대 방향도 시도했다. 정밀도를 더 붙이는 대신 φ^{content} 를 3비트에서 2비트로 떨어뜨려 3 bpw 아래로 내려가 보려는 시도였다. 결과 레이아웃은 각도를 네 개의 대각 사분면 $\{(\pm 1/\sqrt{2}, \pm 1/\sqrt{2})\}$ 에 대응하는 두 부호 비트 (s_x, s_y) 로 인코딩했다. `sincosf` 없이 디퀀트가 가능해지고 블록이 42바이트 (2.625 bpw) 로 줄어들었다.

폐기한 이유. 출력이 완전히 무너졌다. $\pi/2$ (90°) 의 유효 각도 해상도는 temperature 0 생성에서 attention top-1 마진보다 훨씬 낮다. Qwen3-14B 실제 추론에서는 모델이 모든 질의의 첫 몇 토큰 안에 퇴화된 반복 출력을 내기 시작했다. "Hangul" 이라는 단어의 변형이 무한히 도는 식이었다. 한국어 산문, 코드 생성, 수학 추론이 한꺼번에 실패했다. 실패가 워낙 명백하고 총체적이어서 해석의 여지가 없었다. 2비트 각도 해상도는 coupled-RoPE 모델에서 일관된 생성을 하기에 필요한 최소값 아래다.

교훈: **polar 표현이 완전히 작동을 멈추는 최소 각도 해상도가 분명히 존재한다.** 그 경계는 $\pi/4$ (3비트, 사용 가능) 와 $\pi/2$ (2비트, 붕괴) 사이에 있다. 이 절벽의 존재 자체가 유용한 발견이다. 설계 공간이 좁혀지기 때문이다. 즉, polar 프레임워크에서의 비트 절감은 크기 채널이나 잔차 보정에서 나와야지, 주 각도 격자를 더 거칠게 만드는 쪽에서는 나오지 않는다.

Config	Math (/35)	%	vs f16
tbqx3/tbq3 (ours)	**13/35**	**37.1%**	+8%
f16/f16	12/35	34.3%	—
tbq3/tbq3 (TBQ v1)	10/35	28.6%	−17%

Table 3: Qwen3-14B 수학 정확도, seed 1234, 35 문제, temperature 0. TBQX3_1 이 f16 과 기존 TBQ3_1 둘 다를 앞선다. 기존 TBQ3_1 이 f16 대비 −17% 로 내려앉은 것은 §1.1 에서 말한 "3비트 품질 절벽" 그 자체이고, TBQX3_1 은 그 절벽을 닫고 오히려 f16 위로 +8% 올라선다.

9.3 WHT 를 Polar Derotation 과 결합하기

자연스럽게 떠오르는 질문 하나는, 원래 WHT 기반 TBQ 경로의 품질 바닥과 Polar Derotation 의 품질 천장을 같이 쓸 수 있느냐였다. 먼저 K 를 derotate 하고, 페어들에 걸쳐 128-point WHT 를 걸고, WHT 도메인 content 를 표준 Lloyd-Max 로 양자화하고, 읽기 시점에는 셀별로 Q 회전과 셀별 128-point WHT 를 돌린 뒤 WHT 도메인에서 dot product 를 계산하는 구조다.

추구하지 않은 이유. 비용 분석이 말려들었다. Q 의 셀별 WHT 는 셀 사이에서 공유할 수 없다 (각 셀이 고유한 p_K 를, 따라서 고유한 Q_{derot} 를 가지기 때문이다). 결과적으로 모든 KV 캐시 셀 읽기에 $\mathcal{O}(D \log D)$ 짜리 버터플라이 네트워크가 추가되는데, 이는 이미 순수한 메모리 바운드가 아닌 compute-visible 한 어텐션 커널 기준으로 현재 polar 읽기 비용의 약 $10\times$ 에 해당했다. 세 가지 완화책을 고려했으나 전부 기각했다. (i) Q_{derot} 를 사전 계산된 WHT 벡터의 고정 선형 결합으로 분해하는 방식은 셀당 $\mathcal{O}(D^2)$ 로 오히려 더 나쁘다. (ii) 페어 보존 블록 구조 $H_{64} \otimes I_2$ 안에서만 WHT 를 적용하는 방식은, 서로 다른 θ_p 에 대한 페어별 회전과 가환하지 않아서 유효한 사전 양자화 변환이 될 수 없다. (iii) 근사 dyadic 분해는 통제 불가능한 방식으로 양자화 오차를 다시 도입한다. Tangent Residual 이 페어당 FMA 두 개의 비용만으로 drift 격차를 독립적으로 닫아주면서 이 추구는 중단되었다.

교훈: **WHT 의 페어 혼합 구조는 위치 의존적인 페어별 회전과 양립하지 않는다.** 두 변환은 무손실로 합성할 수 없고, 이들을 억지로 협력하게 만드는 실질 비용이 그들이 함께 가져다줄 수 있는 품질 이득을 압도한다.

9.4 φ^{content} Lloyd-Max 코드북의 오프라인 캘리브레이션

크기 채널에서는 Rayleigh Lloyd-Max 가 즉시 작동한다. 분포가 닫힌 형식을 가지고 있기 때문이다. 각도 채널에 대해 비슷한 스킴을 잠깐 고려했다. 대표 워크로드에서 수집한 φ^{content} 히스토그램을 바탕으로 비균등 8-레벨 Lloyd-Max 코드북을 캘리브레이션 하는 식이었다.

폐기한 이유. 경험적이 아니라 철학적이었다. TBQ 는 런타임 양자화기이고, 그 유틸리티는 모델 불가지적이고 캘리브레이션 없이 쓸 수 있다는 점에서 나온다. 같은 커널이 어떤 coupled-RoPE 모델에서도 전처리 없이 동작해야 한다. 모델별 캘리브레이션 데이터를 — 아무리 작더라도 — 도입하는 순간 두 번째 배포 의존성이 생긴다. 캘리브레이션 파일을 엔진과 함께 배포해야 하고, 모델 업데이트 때마다 갱신해야 하고, 토크나이저와 짝을 맞춰야 한다. TBQ 의 운영 프로필이 post-training 양자화 도구 쪽으로 끌려가 버린다. 저자는 구현 노트에서 이 방향을 명시적으로 거부했다. Tangent Residual 은 해석적이므로 캘리브레이션 없이 쓸 수 있다는 속성을 그대로 유지한다.

교훈: **런타임 양자화 시스템은 어떤 종류의 캘리브레이션 데이터에도 큰 운영 비용을 지불하게 된다.** 이론적으로 더 좋은 품질이 가능하더라도, 해석적 대안이 있으면 그쪽을 택해야 한다.

9.5 셀별 적응형 정밀도

비교적 늦게 나온 아이디어 하나는, 런타임에 "모호한" 어텐션 단계를 — top-1 과 top-2 attention logit 이 양자화 잡음 바닥 이내에 있는 셀을 — 감지해서 해당 셀에만 FP32 로 폴백하자는 것이었다. 희소 토큰 질의에서의 drift 가 국소적 현상이라는 관찰이 동기였다. 한 번 추론에서 실제로 근접 동점을 겪는 셀은 극소수다.

추구하지 않은 이유. 구현 복잡도가 수지에 맞지 않았다. 플래시 어텐션 vec 커널 안에 셀별 정밀도 폴백을 넣으려면 둘 중 하나를 해야 한다. (i) 두 패스 어텐션 스킴 — 첫 패스는 저정밀도 점수를 계산하면서 근접 동점을 플래그로 남기고, 두 번째 패스는 플래그된 셀을 고정밀로 재계산 — 이거나, (ii) FP32 사이드 경로를 갖는 워프 수준의 발산 실행 이다. 둘 다 지금 커널을 빠르게 만드는 균일한 SIMT 구조를 깨고, 둘 다 벤치마크하기 까다로운 분기 의존적 지연을 만들어낸다. Tangent Residual 은 같은 기능 목표 — 어텐션 점수 교란을 drift 임계 아래로 끌어내리는 것 — 를 branchless, uniform, 레지스터 국소 보정으로 달성하기 때문에 그쪽이 채택되었다.

교훈: **SIMT 커널에서는 drift 계열 오차에 대해 branchless 해석적 보정이 적응형 정밀도보다 낫다.** 적응형 스킴이 원칙적으로 더 타이트한 오차 한계에 도달할 수 있더라도 그렇다.

9.6 실험 플랫폼: DGX Spark 의 열 천장

초기 실험 기간에 있었던 한 부류의 실패는 소프트웨어 버그도 알고리즘 실수도 아니었지만 따로 기록해둘 가치가 있다. 처음에는 둘 다로 가장하고 있던 하드웨어 envelope 제약이었기 때문이다.

Qwen3-14B 초기 실험 단계에서 장시간 TBQ 벤치마크를 돌리면 간헐적으로 DGX Spark GB10 호스트 전체가 멈췄다. 커널 패닉도, `dmesg` 출력도, NVIDIA 드라이버 오류도, 호스트 OS 가 복구할 방법도 없는 그런 멈춤이었다. 이벤트마다 하드 파워 사이클과 약 5분의 재부팅, 그리고 진행 중이던 연구 컨텍스트 손실을 감수해야 했다. 며칠에 걸쳐 12건 이상이 발생했다. 증상은 처음에 소프트웨어 쪽의 그럴듯한 원인들에 잘못 귀속되었고, 돌이켜보면 이것들은 유익한 red herring 목록을 이룬다.

- *`build_rope_shift`* 디퀀트 경로. CUDA 백엔드에 TBQ ↔ FP32 `cpy` op 가 없어서, 양자화된 캐시에서 컨텍스

트 시프트가 발화하면 스케줄러 실패가 난다. `src/llama-kv-cache.cpp` 에 early-return 가드를 넣었다. GB10 의 통합 메모리 아키텍처에서 스케줄러 실패가 호스트로 전파된다는 가설에 기반한 조치였다. 가드는 지금도 유효하고 의미상으로도 맞지만 (§4.7 참조: Polar Derotation 은 RoPE shift 를 no-op 으로 만든다), 그게 freeze 의 원인은 아니었다.

- *TBQ* 양자화 커널의 스레드별 스택 배열. 3비트 set-rows 양자화 경로는 블록당 256 스레드에서 스레드당 약 1.5 KB 스택을 썼다. aarch64 통합 메모리 SoC 에서는 이것이 호스트 메모리 컨트롤러를 통과하는 local-memory 트래픽을 만들어 낸다. 새 디스패치 래퍼를 통해 스크래치 버퍼를 공유 메모리로 옮겼다. `cuobjdump` 는 변경 전후 모두 `LOCAL:0` 를 보고했다. freeze 는 계속됐다.

- 드라이버 *memdesc* 고갈. 이전의 DGX 크래시 클러스터가 `NVRM: Out of memory @ mem_desc.c:1359` 커널 로그를 남긴 적이 있어서, set-rows 경로의 누적 할당자 누수를 의심했다. MLA 전용 `fattn-common.cuh` 코드의 raw `cudaMalloc`/`cudaFree` 쌍을 풀 할당자로 되돌렸다. 변경 자체는 옳았지만 Qwen3-14B 증상과는 직교했다.

- *TBQP* 전용 코드 경로. TBQP 커널의 Direct Signs 와 QJL 잔차 보정 코드를 잠깐 의심했다. 크래시가 TBQP K 캐시와 상관 있어 보였기 때문이다. TBQ (non-P) 로 이등분해 보니 QJL 이나 Direct Signs 없이도 크래시 패턴이 그대로 나왔다. 상관은 가짜였다.

실제 원인은 실행 중에 GB10 코어 온도를 직접 측정하고 나서야 확인됐다. SoC 가 **85°C** 에 도달하면 펌웨어 강제 열 차단이 걸리고 그 상태로 freeze 되고 있었던 것이다. 이건 소프트웨어 관점에서 보이는 이벤트가 아니다. CUDA 드라이버는 오류를 받지 않고, 호스트 커널은 인터럽트를 보지 않고, 로그는 남지 않는다. 하드웨어가 그냥 멈추기 때문이다. "지속적인 TBQ 워크로드 아래서의 무음 호스트 freeze" 패턴은 정확히 SoC 수준의 열 kill 에서 기대되는 모습이고, 위의 어느 소프트웨어 가설로도 설명이 안 되었다.

열 원인을 찾기 전까지 일주일 동안 우리는 알고리즘 버그를 쫓고 있다고 완전히 확신했다. set-rows 양자화 커널을 읽고 또 읽으며 out-of-bounds 쓰기를 찾았고, vec-dot 내부 루프를 들여다보며 half/float 타입 혼동을 찾았다. 매 시도마다 재부팅과 컨텍스트 손실을 감수하면서 커밋 로그를 한 크래시씩 이등분했다. 단일 가설 하나에 하루 온종일이 소모되고 결국 틀린 것으로 드러나기를 반복했는데, 추론이 나빠서가 아니라 실제 실패가 우리가 가진 모든 도구에 안 보였기 때문이다. 페어별 양자화기에 미묘한 race condition 을 집어넣었다고 몇 시간 동안 확신해 놓고 알고 보니 코드는 처음부터 맞았고 하드웨어가 부하에서 열 트립을 하고 있었더라는 사실을 마주하는 건 특별한 종류의 피로감을 남긴다. 이 논문이 이 에피소드를 기록하는 이유는, 그게 실제로 TBQX3_1 개발 전 과정에서 단일 최대 비용 이벤트였기 때문이다. polar derotation 설계, tangent residual 유도, 커널 통합 작업을 전부 합친 것보다 더 많은 시간을 잡아먹었다. 무음 하드웨어 한계는 엣지 플랫폼 위에 구축된 시스템의 연구 방법론에서 일급 취급을 받을 자격이 있다. 다른 어디에도 흔적을 남기지 않고 예산만 소모하기 때문이다.

해결책은 steady-state 동작 온도를 70°C 초반으로 유지시키는 하드웨어 측 전압 감소였다. 85°C 차단 아래로 넉넉하게 떨어진다. 이 제약이 걸린 뒤의 모든 TBQ 와 TBQX 변종은 incident 없이 완주했고, §7 의 벤치마크는 안정화된 열 envelope 아래서 수집한 결과다.

이 에피소드를 기록해두는 이유는 두 가지다. 첫째, 열 원인을 찾기 전에 우리가 시도한 모든 진단 단계는 잘못된 문제를 향하고 있었다. 효율적이었다면 일주일의 디버깅이 대략 나흘의 소프트웨어 가설 작업으로 압축됐을 텐데, 각 가설은 다른 환경에서는 원인일 수도 있었지만 우리 환경에서는 아니었다. 연구 워크플로에서 무음 하드웨어 실패의 비용은 상당하다. 포렌식 흔적을 남기는 크래시와 달리, 무음 freeze 는 자기 자신의 원인을 지워버린다. 둘째, 이 경험은 열적으로 제약된 엣지 플랫폼에서의 TBQ 계열 워크로드에 대한 방법론적 권고를 바꿔 놓는다. **열 모니터링은 선택이 아니다.** 소프트웨어 관점에서 보이는 신호를 전혀 내보내지 않는 펌웨어 수준 차단은 어떤 소프트웨어 이등분보다 먼저 일급 실패 모드로 취급되어야 한다. 냉각이 충분한 시스템에서는 — 예컨대 같은 워크로드를 incident 없이 돌린 primoco 의 x86+dGPU 참조 환경 — 이 문제가 나타나지 않는다. 외부 재현에서 이 문제가 보이지 않은 이유도 여기에 있다.

9.7 실패 표면 요약

10 결론

본 연구의 핵심 기여는 **프로덕션 LLM 추론 엔진 안에서 coupled-RoPE KV 캐시에 Polar Derotation 을 end-to-end 로 구현한 최초의 사례** 를 만든 것이다. NVIDIA DGX Spark 위 Qwen3-14B 40K 컨텍스트 환경에서 검증되었다. 이 공간의 선행 제안들은 대체로 이론에 머물거나 (PolarQuant 은 극 구조를 분포 shaping 에 쓸 뿐 양자화된 위상에 위치 항을 그대로 남긴다), 아키텍처 재학습을 요구했다 (MLA 는 attention 행렬을 재설계해 content 와 position 을 분리한다). Polar Derotation 은 정확히 그 사이 틈에 자리 잡는다. 캐시 경계에서 적용되는 소급 변환이며, 이미 학습된 가중치 위에서 MLA 와 같은 content/position 분리를 만들어내면서, 학습 비용은 0, 모델 파일 · 토크나이저 · 가중치 포맷 변경도 필요 없다.

두 번째 기여는 **Tangent Residual** 이다. 3비트 uniform 위상 양자화기가 남기는 잔차 각도 오차에 대한 1비트 완전 해석적 보정이다. 이는 Rayleigh Lloyd-Max 가 이미 크기 채널을 거의 최적으로 잡아준 뒤에는 페어당 잔여 오차가 본질적으로 전부 양자화된 위상의 접선 방향에 남는다는 기하학적 관찰에서 유도된다. 보정의 크기 $r \cdot \pi/16$ 는 순수 상수이고, 방향은 디퀀트 중에 이미 계산해둔 코사인/사인의 좌표 치환이며, 저장 비용은 정확히 페어당 1비트다. 캘리브레이션도, 학습된 스케일도, 추가 삼각 함수 호출도 없다.

Polar Derotation 과 Tangent Residual 이 결합되어 3.625-bpw K 캐시 포맷인 **TBQX3_1** 이 된다. 기존 3비트 V 캐시와 짝지었을 때, Qwen3-14B temperature 0 수학 추론에서 **f16 을 앞선다** (37.1% vs 34.3%, seed 1234). KV 캐시는 4.74× 압축되고, 디코드 처리량은 기존 TBQ3_1 과 측정 오차 안에서 같다. 같은 워크로드에서 기존 TBQ3_1 은 f16 보다 17% 낮게 나오는데, 이 격차가 이 논문이 쓰이게 된 3비트 품질 절벽이다. 동일한 스킴은 Tangent Residual 의 동기였던 저확률 토큰 drift — 희소 이름 음역에서 나오던 키릴 문자 오염 — 도 함께 제거한다.

3.625-bpw 양자화 K 캐시가 정확한 정수 답이 요구되는 과제에서 f16 을 앞선다는 사실은 놀라워 보일 수 있지만, 모순은

변종	bpw	결과	주된 실패 원인
TBQXP3_1 (Direct Signs)	4.25	폐기	과지불; 비구조적 잔차 모델
TBQX2_1 (2비트 각도)	2.625	폐기	출력 붕괴 (각도 바닥)
WHT $\oplus$ Polar	3.125	중단	셀별 WHT 비용 $\sim 10\times$
캘리브레이션된 φ Lloyd-Max	3.125	거부	캘리브레이션 없는 속성 훼손
셀별 적응형 FP32 fallback	가변	거부	SIMT 발산 오버헤드
TBQX3_1 (Tangent Residual)	**3.625**	**채택**	—

Table 4: TBQX3_1 개발 과정에서 탐구했다가 폐기한 변종들과 기각 사유. 채택된 구성은 이 모두를 단일 부호 비트 — 기하학적으로 정확한 반 셀 보정을 수반 — 로 대체했다.

아니다. 양자화는 attention 분포에 대한 암묵적 정규화기로 작동한다. f16 은 attention 점수에 들어오는 모든 이상치 잡음 성분을 그대로 보존하는 반면, polar 표현은 content 기하를 더 직접적으로 포착하고 지배적 attention 피크에 기여하지 않는 고차 위상 잡음은 버린다. 효과 자체는 페어당 작지만, 40 레이어와 40,960 토큰을 통해 누적되면 temperature 0 정확 일치 벤치에서 측정 가능한 정확도 델타로 나타난다. 이를 §7 의 데이터로 뒷받침되는 실용적 관찰로 제시할 뿐, 양자화가 항상 도움이 된다는 일반적 주장으로 내세우는 것은 아니다. 같은 벤치에서 기존 TBQ3_1 은 f16 보다 뚜렷이 낮고, polar 양자화기의 바이트 패턴을 살짝만 바꾼 (TBQX2_1) 것만으로 출력이 완전히 붕괴한다. 품질이 통하는 영역은 좁고 구조 의존적이다.

우리는 이 작업을, PolarQuant 이 pair-polar 좌표를 분포 shaping 에 쓴 방식과 MLA 가 아키텍처 차원에서 content 와 position 을 분리한 방식 사이에 있던 잃어버린 중간 단계로 본다. 즉, coupled-RoPE 모델의 거대한 설치 기반에 재학습을 요구하지 않고 content/position 분리 이점을 전달하는 소급, 비트 중립, 모델 불가지 변환이다. 참조 구현은 llama.cpp 의 23 개 파일 수정이며, 전부 head_dim=128 polar 경로 하나에만 국한된다. 다른 모든 구성 (head_dim=64, head_dim=256, MLA 변종) 이 영향을 받지 않는다는 사실도 검증되어 있다.

감사의 글

본 연구는 NVIDIA DGX Spark 위에서 독립적으로 수행되었다. 저자는 llama.cpp 커뮤니티, 이론적 토대를 제공한 TurboQuant 과 PolarQuant 의 저자들, 그리고 content/position 분리가 추구할 가치가 있음을 아키텍처적으로 보여준 DeepSeek MLA 저자들에게 감사를 표한다.

References

[1] J. Su, Y. Lu, S. Pan, A. Murtadha, B. Wen, Y. Liu. RoFormer: Enhanced Transformer with Rotary Position Embedding. *arXiv:2104.09864*, 2021.

[2] I. Han et al. PolarQuant: Quantizing KV Caches with Polar Transformation. *arXiv:2502.02617*, 2025.

[3] A. Zandieh, V. Mirrokni et al. TurboQuant: Online Vector Quantization with Near-optimal Distortion Rate. In *Proceedings of ICLR*, 2026.

[4] AmesianX. TurboQuant in Practice: Implementing 3-Bit KV Cache Compression in a Production LLM Inference Engine. Working paper, 2026. https://github.com/AmesianX/TurboQuant

[5] DeepSeek-AI. DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. *arXiv:2405.04434*, 2024.

[6] Z. Liu, J. Yuan, H. Jin, S. Zhong, Z. Xu, V. Braverman, B. Chen, X. Hu. KIVI: A Tuning-Free Asymmetric 2bit Quantization for KV Cache. In *ICML*, 2024.

[7] C. Hooper, S. Kim, H. Mohammadzadeh, M. W. Mahoney, Y. S. Shao, K. Keutzer, A. Gholami. KVQuant: Towards 10 Million Context Length LLM Inference with KV Cache Quantization. *arXiv:2401.18079*, 2024.

[8] G. Xiao, J. Lin, M. Seznec, H. Wu, J. Demouth, S. Han. SmoothQuant: Accurate and Efficient Post-Training Quantization for Large Language Models. In *ICML*, 2023.

[9] M. Payne, R. Hanek. Radian Reduction for Trigonometric Functions. *ACM SIGNUM Newsletter*, 18(1):19–24, 1983.