TurboQuant v1.2.0

업무일지 / Work Log

2026-03-31 21:00 ~ 04-01 05:47

총 8시간 47분

llama.cpp KV Cache Compression

AmesianX

세션 개요

- 21:00 ~ 21:30 — 현황 파악 + 작업 계획 수립
- 21:30 ~ 22:30 — v2 Kronecker 버그 분석
- 22:30 ~ 00:30 — V cross-head WHT 구현
- 00:30 ~ 02:00 — 과학자 이름 테스트 (품질 검증)
- 02:00 ~ 02:30 — 논문 검증 + head_dim 한계 확정
- 02:30 ~ 03:00 — head_dim=64 해결책
- 03:00 ~ 04:00 — Auto head_dim Mapping 구현
- 04:00 ~ 05:47 — 리뷰, 벤치마크, 배포, 커뮤니티

v2 Kronecker 버그 분석 디버깅

- `set-rows.cu` 의 v1 (serial 512-WHT) vs v2 (Kronecker $H_8 \otimes H_{64}$) 심층 비교
- 부호 패턴, butterfly 방향, `__syncthreads__` 배치, warp shuffle mask 전수 검증
- standalone CUDA 테스트 작성 — `test-xhead-v1-v2.cu`

결론: v1 == v2 (max error 1e-6) — 알고리즘 자체는 정확. PPL 차이는 빌드/통합 문제.

V Cross-Head WHT 구현 신규 기능

핵심 수학

$$V_{real,h}[j] = (1/8)\ \Sigma_g\ H_8[h,g] \times \text{dequant}(V_{block,g}[j])$$

수정 파일

FATTN-VEC.CUH

V 누적 루프에 8-head 로드 + H_8 inverse 결합

V IWHT에 head-specific signs 적용

FATTN.CU

V=_3 FATTN_VEC_CASE dispatch 추가 (8개 조합)

VEC 라우팅에 V TBQ 타입 체크

CMAKELISTS.TXT

8개 신규 template instance 등록

결과

PPL 20% 개선

3315 → 2649 (per-head V 대비)

과학자 이름 테스트 핵심 발견

독일 물리학자 이름 "Wolfgang Pauli"의 한국어 음차 정확도로 토큰 레벨 품질 검증

양자화	PPL	출력	판정
F16 / F16	4008	"볼프강 파울리"	PASS
tbqp3_3 / f16	**2195**	"2."	FAIL
tbq4_0 / f16	3421	"볼프강 파우리"	1음절 차이
tbq3_0 / f16	3089	"파이브라스"	FAIL

PPL 함정 발견: WHT가 attention smoothing으로 PPL은 개선하지만, peak 정밀도를 파괴 — PPL과 생성 품질이 역상관

head_dim 한계 확정 분석

논문 범위: TurboQuant 논문은 head_dim=128만 검증 (Gemma, Mistral, Llama-3.1-8B)
head_dim=64는 CLT(중심극한정리) 수렴 부족이 근본 원인

head_dim별 테스트 결과

64	128	256
생성 깨짐	과학자 이름 정확	과학자 이름 정확
NOT OK	PASS	PASS

결론: TurboQuant WHT는 **head_dim ≥ 128**에서만 실용적

head_dim=64 해결 + Auto Mapping 해결

HEAD_DIM=64 해결책

- K = `q8_0` (표준 8-bit)
- V = `tbq3_2` (WHT 3-bit)
- "볼프강 파울리" 정확 출력 확인
- 2.7x 압축률 유지

AUTO HEAD_DIM MAPPING

- 사용자 입력: `tbq3` (단축어)
- GGUF 메타데이터에서 head_dim 자동 감지
- 256 → `_0` / 128 → `_1` / 64 → K= `q8_0` +V= `_2`
- 입력 검증 + fallback + 경고 박스

수정 파일

- `arg.cpp` — shorthand 매핑
- `common.cpp` — head_dim 감지 + 자동 선택

GPT OSS 20B/120B, Qwen3.5-27B/122B — 전 모델 테스트 통과

리뷰 / 벤치마크 / 배포 완료

코드 리뷰 + 버그 수정

- Agent 활용 전체 코드 리뷰 (4개 파일)
- V wrong-suffix fallback: `q8_0` → `f16` 수정
- TBQP V downgrade 로직 정리
- 재빌드 + 검증 통과

벤치마크 수집

- GPT OSS 20B/120B: F16 vs auto-mapped
- Qwen3.5-122B: F16 vs tbqp3/tbq3
- KV 크기, 압축률, 속도, PPL 비교

배포

- patch 파일 생성 (전체 + 파일별 13개), modified_files 업데이트 (68 파일)
- main push → **v1.2.0 태그** → GitHub 릴리즈 생성 → 워크플로우 트리거
- llama.cpp discussion #21155, #20969에 업데이트 공유

핵심 성과 요약

6	8h 47m	v1.2.0
주요 성과	작업 시간	릴리즈 배포

- **V cross-head WHT 구현 완료** — per-head V 대비 PPL 20% 개선
- **PPL 함정 발견** — head_dim=64에서 PPL↓ but 생성품질↓ (역상관)
- **Auto head_dim mapping** — `tbq3` 입력만으로 head_dim 자동 선택
- **head_dim=64 해결** — K=q8_0 fallback + V=tbq3, 파울리 테스트 통과
- **입력 검증 강화** — 어떤 조합이든 크래시 없이 안전 처리
- **v1.2.0 릴리즈 + 커뮤니티 공유**

감사합니다

TurboQuant v1.2.0

2026-04-01