TurboQuant v1.3.0

업무일지 / Work Log

2026-04-01 14:00 ~ 23:00

총 9시간

head_dim P1-P5 + 커뮤니티 이슈 전체 해결 + TheTom fork 분석

AmesianX

세션 개요

- 14:00 ~ 14:30 — 업무일지 PDF + GitHub Actions 정리
- 14:30 ~ 15:00 — 커뮤니티 피드백 분석 (6개 이슈)
- 15:00 ~ 15:30 — v1.2.0 빌드 문제 + standalone 빌드
- 15:30 ~ 18:00 — head_dim P1-P5 Priority Cascade 구현
- 18:00 ~ 19:00 — turbo4 PPL + "////" 재현 테스트
- 19:00 ~ 20:00 — v1.3.0 릴리즈 + 커뮤니티 공유
- 20:00 ~ 21:00 — Distill 벤치마크 + 과학자 이름 테스트
- 21:00 ~ 22:00 — 코드 리뷰 + 커뮤니티 대응
- 22:00 ~ 23:00 — TheTom fork turbo4 분석 + 댓글 수정

head_dim P1-P5 Priority Cascade 핵심

기존: GGUF `attention.key_length`만 읽음 → 대부분 모델에서 TurboQuant 조용히 비활성

우선순위	SIGNAL	신뢰도	비고
P1	`attention.key_length`	**100%**	GGUF 공식값
P2	`key_length_mla`	**100%**	DeepSeek V2 등
P3	`key_length_swa`	**100%**	Gemma 2/3 등
P4	`value_length`	95%	교차 검증
P5	`n_embd / n_head`	**70%**	MoE에서 오류!

P5 함정: Qwen3-MoE는 n_embd/n_head=64이지만 실제 head_dim=**128**. Qwen3.5-27B는 213이지만 실제 **256**.

커뮤니티 이슈 전체 해결 완료

이슈	보고자	상태
Phi-4, DeepSeek head_dim 감지 실패	@fritolays	**수정**
turbo4-K PPL 폭발 (18,202)	@TheTom	**수정**
GLM head_dim=576, Qwen3-4B head_dim=80	@fritolays, @sztlink	**수정**
"////" 출력 (Qwen3.5-27B-UD)	@modderBUG	재현 불가
llama-bench TBQ 미지원	@sztlink	**수정**
Windows OpenSSL DLL 의존성	@sztlink	**수정**

turbo4-K PPL + "////" 출력 검증 해결

TURBO4-K PPL (QWEN3-30B-A3B)

f16/f16	**6.26**	baseline
tbq4/tbq4	**6.73**	+7.5%
tbq3/tbq3	8.49	+35.6%

정상 — 폭발 없음!

"////" 출력 재현 (QWEN3.5-27B-UD)

- tbqp3/tbq3로 테스트
- 정상 출력 확인
- P1이 head_dim=256 정확히 감지
- n_embd/n_head=213 → P5 틀림

재현 불가 — 환경 특이

결론: 두 이슈 모두 head_dim 오감지가 근본 원인. P1→P5 캐스케이드로 해결.

Distill 모델 벤치마크 신규

Qwen3.5-27B-Claude-4.6-Opus-Reasoning-Distilled Q4_K_M, head_dim=256

설정	PPL	VS F16	KV 메모리	압축
f16/f16	**6.16**	기준	8,192 MiB	1.0x
tbqp4/tbq4	**6.20**	**+0.6%**	2,096 MiB	**3.9x**
tbqp3/tbq3	**6.23**	**+1.1%**	1,584 MiB	**5.2x**
tbq4/tbq4	7.01	+13.8%	—	—
tbq3/tbq3	7.11	+15.4%	—	—

head_dim=256 + QJL: 5.2x 압축에 PPL +1.1% — 거의 무손실

과학자 이름 테스트 (6명) 통과

tbqp3/tbq3 (5.2x 압축), Qwen3.5-27B-Claude-4.6-Opus-Distilled

과학자	출력	표준 표기	판정
Wolfgang Pauli	볼프강 파울리	볼프강 파울리	**PASS**
Niels Bohr	니엘스 보어	닐스 보어	OK*
Erwin Schrödinger	에르빈 슈뢰딩거	에르빈 슈뢰딩거	**PASS**
Werner Heisenberg	베르너 하이젠베르크	베르너 하이젠베르크	**PASS**
Max Planck	막스 플랑크	막스 플랑크	**PASS**
Enrico Fermi	에리코 페르미	엔리코 페르미	OK*

* 통용되는 표기이나 표준과 미세 차이 — 중국 LLM 특성 (TurboQuant 무관, F16 동일 출력)

코드 리뷰 수정 품질

CRITICAL (2개)

- pow2 검증 후 `head_dim=0` 리셋 누락
- V fallback 타입 불일치 (f16 vs q8_0) 통일

MEDIUM (1개)

- TBQ 미사용시 감지 로직 전체 스킵
- 불필요한 메타데이터 읽기 + 로그 제거

> 수정 후 재빌드 + 파울리 테스트 통과 + patches/modified_files 재생성 완료

커뮤니티 대응 소통

- **@dagbdagb** — "6 signals" 오류 지적 → "5-level cascade" 수정
- **@sztlink** — RTX 4090 벤치 감사 + v1.3.0 재테스트 요청
- **@zekrom-vale** — turbo4 폭발은 head_dim 오감지, 우리 fork 정상
- **@Defilan** — SM 120 테스트 환영 + upstream 통합 계획 공유
- **@fritolays** — 7-아키텍처 벤치 감사 + Phi-4/DeepSeek 재테스트 요청
- **@yajo** — BitNet+TurboQuant 직교 관계 설명

> **Upstream 계획:** 안정화 후 llama.cpp 메인에 PR 예정. 현재는 turboquant/ 디렉토리에 패치+diff 관리 중.

TheTom Fork 분석 분석

- **TheTom의 turboquant_plus fork 코드 분석**
- **turbo4-K PPL 폭발의 실제 원인:** 7개 커널 버그 (SET_ROWS 패킹 불일치, QJL 단계 누락 등)
- **우리 fork는 독립 구현**이라 해당 버그 없음
- **댓글 수정:** "head_dim misdetection" → "TheTom fork 자체 커널 버그"로 정정
- **TheTom에게 분석 결과 공유** + turbo4-resurrection 논문 인정

> **핵심:** turbo4 PPL 폭발은 TheTom fork의 커널 버그 7개가 원인. 우리 독립 구현과는 무관.

핵심 성과 요약

7
이슈 해결

9h
작업 시간

v1.3.0
릴리즈 배포

- **P1→P5 Priority Cascade** — 6-signal 크로스 밸리데이션
- **커뮤니티 이슈 6/6 해결** — Phi-4, turbo4, GLM, ////, llama-bench, OpenSSL
- **Distill 벤치** — PPL 6.23 (+1.1%), 5.2x 압축 거의 무손실
- **과학자 이름 6/6** — head_dim=256 QJL 정밀도 완벽 유지
- **코드 리뷰 반영** — Critical 2건 + Medium 1건 수정
- **커뮤니티 8명 대응** — upstream 통합 계획 공유

- **TheTom fork 분석** — turbo4 PPL 폭발은 커널 버그 7개, 우리 독립 구현과 무관 확인

감사합니다

TurboQuant v1.3.0

2026-04-01

Speaker notes