TurboQuant v1.4.0

업무일지 / Work Log

2026-04-02 ~ 04-03

GLM-4.7-Flash + V Cache Bug Fix

head_dim=576 블록 분할 구현

IWHT FP16→FP32 정밀도 수정

AmesianX

세션 개요

- 04-02 PM — GLM-4.7-Flash head_dim=576 설계 문서 검토 + 구현 계획
- 04-02 PM — 타입 시스템 + 블록 구조체 + auto-mapping + 양자화 커널 구현
- 04-02 PM — K dot product + V dequant + Q 전처리 + IWHT 구현
- 04-02 PM — Template dispatch + 20개 instance 파일 + 빌드 시스템
- 04-02 EVE — 빌드 성공 + GLM-4.7-Flash 생성 테스트 (49.4/65.6 t/s)
- 04-02 EVE — GitHub Issue #2 버그 재현 (Windows + Linux)
- 04-02 EVE — V 캐시 IWHT FP16 정밀도 버그 발견 + FP32 수정
- 04-03 AM — Q 전처리 WHT도 FP32로 통일 (ROCm 호환)
- 04-03 AM — v1.4.0 릴리즈 + 워크플로 + 커뮤니티 댓글

GLM-4.7-Flash head_dim=576 핵심

WHT는 power-of-2만 지원 → 576 = **256 + 256 + 64** 블록 분할로 해결

블록	범위	WHT	보정	커널
Sub-block 1	[0, 256)	WHT_256	QJL SRHT	기존 _0 재활용
Sub-block 2	[256, 512)	WHT_256	QJL SRHT	기존 _0 재활용
Sub-block 3	[512, 576)	WHT_64	Direct Sign	기존 _2 재활용

시뮬레이션 결과: MSE -3.4% vs Full QR 직교 회전, 메모리 오버헤드 0%. 256이 sweet spot — 512 한 덩어리보다 256 두 개가 MSE 낮음.

시뮬레이션 비교 (500회 반복, 3-bit) 검증

방법	MSE	VS FULL QR	저장	오버헤드
FullPad 1024	0.063	-40.6%	1024	78%
256+256+64	**0.102**	**-3.4%**	**576**	**0%**
Full QR ortho	0.106	기준	576	0%
512+64	0.108	+2.5%	576	0%
Kronecker H64⊗O9	0.112	+5.2%	576	0%
No rotation	0.569	+435%	576	0%

구현 상세 32 files

타입 시스템

- 4 enum: TBQ3_4 ~ TBQP4_4 (ID 57-60)
- 4 composite block struct (228-300B)
- blck_size = 576, type_traits 등록

양자화 (ENCODING)

- 4 quantize 함수 (sub-block별 독립 WHT)
- Sub-block 1,2: QJL SRHT 보정
- Sub-block 3: Direct Sign 보정

역양자화 (DECODING)

- K dot product 4개 + V dequant 2개
- Q 전처리: 3-pass split WHT
- V IWHT: 3-pass 역변환 → dst

인프라

- 20 template instance (.cu) 파일
- CMakeLists + fattn.cu dispatch
- auto-mapping head_dim=576 → _4

V 캐시 IWHT FP16 정밀도 버그 치명적

증상

- ~1500-2300토큰 이후 `////` 또는 `???` 반복
- tbqp3: ~1826tok에서 발생
- tbqp4: ~2284tok에서 발생
- f16 V: 문제 없음

원인 분석

- V IWHT butterfly가 FP16(half)으로 수행
- 누적된 WHT 도메인 값 → FP16 정밀도 초과
- Catastrophic cancellation in subtraction
- K만 양자화 → 정상, V만 양자화 → 손상

K/V 분리 테스트가 핵심: tbqp3 K + f16 V = 정상 / f16 K + tbq3 V = 손상 → V 경로 특정

수정: WHT/IWHT 전체 FP32 전환 해결

경로	수정 전	수정 후	영향
V IWHT (D=256/128/64/576)	FP16 butterfly	FP32 butterfly	corruption 해결
Q WHT MSE (D=256/128/64/576)	FP16 butterfly	FP32 butterfly	정밀도 + ROCm
Q WHT QJL (D=256/576)	FP16 butterfly	FP32 butterfly	정밀도 + ROCm

검증 결과

Qwen3.5-27B tbqp3/tbq3	4096 tok	NO CORRUPTION
파울리 테스트	볼프강 파울리	정확
하이젠베르크 테스트	베르너 하이젠베르크	정확

부수 효과

- KV 캐시 압축률: 변화 없음
- 속도 오버헤드: 측정 불가 수준
- ROCm/HIP 빌드 호환성 개선
- `__shfl_xor_sync` half → float

커뮤니티 이슈 대응 완료

이슈	보고자	내용	상태
#2	@alrunan	//// 출력 (RTX 5090, Qwen3.5-27B)	**v1.4.0 수정**
#2	@superherointj	Linux NixOS에서도 동일 재현	**v1.4.0 수정**
#3	@jarkevithwlad	standalone 크래시 (RTX 3090)	v1.4.0 시도 요청
#4	@dpblnt	Vulkan SET_ROWS 미지원	CUDA 전용 안내
#5	@dpblnt	ROCm(HIP) 빌드 실패	**FP32 전환으로 해결**
#6	@jarkevithwlad	Gemma 4 아키텍처 미인식	upstream 필요

v1.4.0 릴리즈 배포

32	4	0
수정/추가 파일	새 타입 (TBQ_4)	Corruption (4096tok)

- GitHub 릴리즈: v1.4.0 생성 + 릴리즈 노트
- 빌드 워크플로 트리거 (Linux x64/arm64, Windows x64, CUDA 12.8)
- README.md 업데이트 (한국어 + 영어)
- Issue #2, #3, #4, #5, #6 댓글 대응
- llama.cpp Discussion #20969 공지
- turboquant/ 디렉토리 백업 (modified_files + patches)