TurboQuant v1.5.0

Work Log

2026-04-04 | Upstream Rebase + Gemma 4 Support

Full 3-way merge rebase | head_dim=512 vec kernel | AmesianX

Session Overview

- AM — Full source rebase on latest upstream llama.cpp (b7ad48ebd)
- AM — 3-way merge (diff3): base=27b93cbd1, 26 conflicts auto-resolved
- PM — Build success + GLM-4.7-Flash / Qwen3.5-27B verified
- PM — main branch swap (main-old backup), force push
- PM — Gemma 4: SWA remap + attn_rot_k fix + D=512 2-pass WHT
- EVE — Gemma 4 31B Dense + 26B MoE benchmark
- EVE — Qwen3-14B V-cache issue #11 verified (f16=TBQ identical))
- EVE — v1.5.0 release + community comments (#20969) (#20969)
- EVE — First auto-merge success (0 conflicts, 2 files))

Upstream Rebase Core

PROBLEM

- 기존: upstream과 별도 히스토리
- 동기화 = 수백 커밋 수동 패치
- `git merge-base` 불가

RESOLVED

- fork point: `27b93cbd1`
- `diff3 -m` 3-way merge
- TBQ overlap → ours, 비-TBQ → upstream

Result: 앞으로 `git fetch upstream && git merge upstream/master` 한 줄로 동기화. 첫 자동 머지 테스트: **충돌 0개**, 2개 파일 자동 합침.

Gemma 4 지원 New

Gemma 4: hybrid SWA — global head_dim=512 (10L) + SWA head_dim=256 (50L), 가변 GQA (16/4)

버그 1: SWA 타입 불일치

global head_dim=512로 매핑된 TBQ 타입이 SWA Cache(256)에도 적용 → 크래시

수정: `llama_kv_cache_iswa` 에서 SWA head_dim 감지, 자동 재매핑

버그 2: ATTN_ROT_K 비활성화

가변 GQA → `is_n_embd_k_gqa_variable()=true` → WHT rotation 꺼짐 → garbage

수정: TBQ 타입일 때 variable GQA 체크 우회

버그 3: D=512 Q WHT 미처리

_0 타입 Q WHT가 256 단일 블록만 처리. D=512면 절반 누락

수정: `n_sub_blocks = D/256` 루프로 2-pass

D=512 VEC DISPATCH

`FATTN_VEC_CASE(512, ...)` 추가

`get_best_fattn_kernel`: D≤512 TBQ → VEC

template instance 16개 추가

벤치마크: Gemma 4 Verified

31B-it Dense (UD-Q4_K_XL, DGX Spark GB10)

CACHE	GPU MEM	COMPRESS	PP T/S	TG T/S	PPL	MATH
f16/f16	41,500 MiB	1.0x	152.9	10.1	309.7	42/6 (64.6
tbqp3/tbq3	**23,215 MiB**	**1.8x**	112.9	9.0	212.1	32/6 (49.2

26B-A4B MoE (UD-Q4_K_XL, DGX Spark GB10)

CACHE	GPU MEM	COMPRESS	TG T/S	MATH	PAULI
f16/f16	5,720 MiB	1.0x	56.4	37/65 (56.9%)	**PASS**
tbqp3/tbq3	**1,106 MiB**	**5.2x**	41.1	30/65 (46.2%)	**PASS**

> 65개 테스트 중 f16과 TBQ는 **55개(Dense)/58개(MoE)에서 동일한 결과**. 차이는 작은 수치 오차 (예: 160→150, 519→509).

이슈 #11 Verified: Qwen3-14B Resolved

V-cache 정밀도 버그 보고 — Rust bindings, head_dim=128, 1500t+ recall 저하 주장

CACHE	MATH 정확도	KV 메모리
f16/f16	22/65 (33.8%)	20,480 MiB
tbqp3/tbq3	**22/65 (33.8%)**	**8,160 MiB**

Result: f16과 TBQ **완벽 동일 정확도**. divergent 18개 중 f16 9승, TBQ 9승. 모델 자체 한계(33.8%)이지 TBQ Problem 아님. **메모리 2.5배 절약.**

이슈 대응 Community

#	제목	대응	상태
#11	V-cache 정밀도 (Qwen3-14B)	벤치 돌려서 f16=TBQ 증명	**답변**
#12	Metal GPU 지원 요청	CUDA 전용, 2200줄+ 포팅 필요 설명	**답변**
#9	Gemma 4 지원 요청	구현 완료, 벤치마크 게시	**닫음**
#6	Gemma 4 지원 (중복)	#9 참조	**닫음**
#20969	llama.cpp 디스커션	v1.5.0 벤치 + 대결표 게시	**게시**

v1.5.0 성과 요약

5.2x
Gemma 4 MoE Compress

0
upstream 머지 충돌

5
지원 아키텍처

4/4
Pauli PASS

Remaining Work: Gemma 4 Math 정확도 개선 (tbq4 4-bit 테스트), MMA 텐서코어 D=512 이식, upstream 정기 동기화 (1-2주 간격)

Speaker notes