TurboQuant v1.5.2

업무일지 / Work Log

2026-04-07

PPL 21%→8%, Attention Sharpening + V Rotation 버그 수정

MMSE 기반 α 유도

attn_rot_v 버그 발견

TBQ3/TBQP3 분리 α

AmesianX

세션 개요

- 오전 — PPL 벤치마크 조사 — ctx=2048에서 f16 대비 21% 격차 발견
- 오전 — 코드 감사 — 1.15x V heavy-tail 보상이 경험적 해킹임을 확인
- 오후 — Per-block norm 구현 (global norm → TBQ3 D=512 블록별)
- 오후 — 1.15x V 보상 제거
- 오후 — Sub-block scale 실험 (32-element 그룹) — WHT가 이미 분산 균등화함을 증명
- 저녁 — 돌파구 — MMSE 이론에서 Attention Sharpening α = 1 + 1/(2×SQNR) 유도
- 저녁 — V rotation 버그 발견 (attn_rot_v=1이나 IWHT에 역회전 없음)
- 야간 — TBQ3 (1.016) vs TBQP3 (1.036) 분리 α — 다른 노이즈 프로파일

◉ 야간 — 최종 PPL 454.7 (f16 대비 1.08x), math bench 19.1/35 vs f16 20.1/35

PPL 격차 조사 문제

현상

- v1.5.1: PPL 509.9 (f16 419.8 대비 **1.21x**)
- q4_0은 1.03x 격차 → TBQ3의 1.21x는 비트 수 대비 과도
- 3-bit이 4-bit보다 왜 이렇게 나쁜가?

근본 원인

- 비트 수가 아닌 **스케일 팩터 수**가 핵심
- q4_0: 512차원당 스케일 16개
- TBQ3: 512차원당 스케일 **2개**
- 스케일 부족 → 양자화 노이즈 누적

핵심: TBQ3의 문제는 3-bit 자체가 아니라, 블록당 스케일 팩터가 적어서 softmax 분포가 평탄화되는 것. 스케일을 늘리는 대신 다른 접근이 필요.

Sub-block Scale 실험 실패

실험 설계

- `block_tbq3_0` 구조체에 8개 서브스케일 추가
- 32-element 그룹별 독립 스케일
- 목표: 세밀한 스케일로 PPL 개선

결과

- PPL **악화**: 514.6 vs 기존 509.9
- 서브스케일 자체가 양자화 노이즈 추가
- WHT가 이미 분산 균등화 수행 중

> **교훈:** WHT(Walsh-Hadamard Transform)는 이미 계수 분산을 균등화한다. 서브스케일은 중복이며 오히려 노이즈만 추가. → 스케일이 아닌 **attention 보정**으로 방향 전환.

Attention Sharpening 돌파구

이론적 배경

- 3-bit 양자화 노이즈가 softmax 분포를 평탄화
- MMSE 이론에서 유도: `α = 1 + 1/(2×SQNR)`
- $SQNR_{3bit} \approx 13.8 \rightarrow \alpha \approx 1.036$

장점

- **메모리 비용 0** — 스칼라 곱셈 하나
- **연산 비용 0** — softmax 전 단일 multiply
- 이론적 근거 있는 보정 (경험적 해킹 아님)

결과: PPL 509.9 → **455.0** (1.21x → **1.08x**). 메모리/연산 추가 비용 없이 PPL 격차 62% 감소.

V Rotation 버그 버그 수정

문제

- `attn_rot`이 K와 V 모두에 적용
- K: 안전 — Q도 같은 회전, 내적에서 상쇄
  `(R·Q)·(R·K) = Q·K`
- V: **버그** — IWHT 디코드에 역회전 없음
- V 출력이 회전된 상태로 나감

수정

- `attn_rot_v = false` 설정
- K만 회전 적용, V는 원래 값 유지
- IWHT가 올바른 원본 V를 복원
- PPL: 455.0 → **448.1** (1.08x → 1.07x)

> **원리:** K 회전은 Q·K 내적에서 $R^T R = I$ 로 상쇄되지만, V는 가중합 후 직접 출력되므로 회전이 남아있으면 결과가 왜곡된다.

TBQ3 / TBQP3 분리 α 최적화

TBQP3 (2-BIT + QJL)

- QJL 프로젝션이 attention 스코어에 추가 노이즈
- 더 강한 sharpening 필요
- **α = 1.036**

TBQ3 (3-BIT)

- 깨끗한 노이즈 프로파일
- 가벼운 sharpening 충분
- **α = 1.016**

결과: 단일 α 대비 분리 α 적용으로 tbqp3/tbq3 PPL: 473.7 → **454.7**. 각 양자화 방식의 노이즈 특성에 맞는 보정.

Per-block Norm 개선

TBQ3 (3-BIT)

- Per-block norm 적용
- 각 256-half 독립 정규화
- 블록별 분산 차이를 정확히 포착

TBQP3 (2-BIT + QJL)

- Global norm 유지
- QJL residual이 cross-block 512-WHT 사용
- 블록 간 정보 공유 필요

설계 원칙: TBQ3는 256 블록 독립 → per-block norm이 자연스럽고, TBQP3는 512 전체 WHT → global norm이 올바른 선택.

tbq4_0 OOB 버그 수정 버그 수정

문제

- `vec_dot_fattn_vec_KQ_tbq4_0`
- D=512에서 `K_tbq[0]`만 읽음
- 나머지 256 차원 미처리 → 잘못된 결과

수정

- `n_blocks = D/256` 루프 적용
- 모든 블록 순회하여 완전한 내적 계산
- D=256, 512 모두 정상 동작

최종 결과 v1.5.2

항목	F16	TBQP3/TBQ3	비율
PPL (ctx=2048)	419.8	**454.7**	**1.08x**
Math Bench	20.1/35	19.1/35	95%
Math Peak	21	**23**	**>f16**
KV 메모리	5,420 MiB	**1,290 MiB**	**4.2x 압축**

1.08x
PPL (v1.5.1: 1.21x)

4.2x
KV 캐시 압축

0
추가 메모리 비용

62%
PPL 격차 감소

v1.5.2 성과 요약

- Attention Sharpening: MMSE 이론 기반 α 유도, 메모리/연산 비용 0
- V Rotation 버그 발견 및 수정: IWHT 역변환에 역회전 부재
- TBQ3/TBQP3 분리 α: 노이즈 프로파일별 최적 보정
- Per-block norm: TBQ3 블록 독립, TBQP3 글로벌 유지
- Sub-block scale 실험: WHT 분산 균등화 효과 증명 (음성 결과도 가치)
- tbq4_0 OOB 버그 수정: D=512 멀티블록 루프

> **v1.5.1 → v1.5.2:** PPL 509.9 → 454.7 (1.21x → 1.08x). 이론적 근거 있는 단일 스칼라 보정으로 양자화 품질을 대폭 개선. 4.2x 압축에서 f16 대비 8% 이내 PPL 달성.

Speaker notes