TurboQuant v1.5.2+

업무일지 / Work Log — Session 3 (PM)

2026-04-08 오후

tbq4 D=512 수정 + head_dim=64 Cross-Head WHT 돌파

4비트 WHT 도메인 불일치 수정

MMSE 동적 소프트닝

QJL 노이즈 발견

파울리 테스트 통과

AmesianX

세션 개요

- 오후 — tbqp4/tbq4 테스트 — garbage 출력 발견, 수학벤치 돌림
- 오후 — 근본 원인: tbq4_0/tbqp4_0 D=512 인코딩에 512-point WHT 누락
- 오후 — 수정: quantize_f32_tbq4_0_block_512 + tbqp4_0_block_512 추가
- 오후 — tbqp4/tbq4 수학벤치 20/35 = f16 동점 달성!
- 오후 — PPL 벤치: tbqp4/tbq4 1.08x vs f16 (tbqp3/tbq3 1.19x 같은 파일 기준)
- 저녁 — head_dim=64 도전 — cross-head WHT 재시도
- 저녁 — global L2 norm → per-head RMS norm 수정
- 저녁 — 동적 샤프닝 _2/_3 적용 시도 → 악화 (SQNR 값 부적절)
- 야간 — MMSE 이론: D=64는 샤프닝이 아니라 **소프트닝** 필요!
- 야간 — K=f16 V=tbq3 실험 → 완벽 (V는 문제 아님, K가 병목)

- 야간 — 핵심 발견: QJL이 D=64에서 K 스코어 노이즈 주범!
- 야간 — tbqp3 → tbq3 자동 전환 (QJL 제거) → **파울리 테스트 통과!**

tbq4/tbqp4 D=512 수정 버그 수정

문제

- tbq4_0/tbqp4_0 인코딩: 256-point WHT만 수행
- Q 전처리: 512-point WHT 수행
- WHT 도메인 불일치 → garbage 출력
- tbq3는 이미 512 버전 있었음

수정

- `quantize_f32_tbq4_0_block_512` 추가
- `quantize_f32_tbqp4_0_block_512` 추가
- set-rows.cu: head_dim≥512 디스패치
- 수학벤치 20/35 = f16 동점 ✓

Cross-Head WHT 돌파 브레이크스루

1. PER-HEAD RMS NORM

- 이전: global L2 norm (8 head 공유)
- 문제: 에너지 큰 head가 norm 지배
- 작은 head 정보 손실 → garbage
- 수정: 각 head 독립 RMS norm

2. QJL 노이즈 발견

- TBQP3: 2-bit MSE + 1-bit QJL
- QJL의 랜덤 프로젝션 → K 스코어 노이즈
- D=256: 노이즈 작음 (무시 가능)
- **D=64: 노이즈가 signal gap 초과!**

> **해법:** head_dim=64에서 K를 tbqp3 → tbq3 자동 전환. 3비트 전부 Lloyd-Max centroid에 투자. SQNR 2.3배 향상 (3.45 → 7.8).

MMSE 동적 소프트닝 이론

D≥256: 샤프닝 (A > 1)

- SQNR 높음 → 올바른 토큰이 거의 항상 1등
- softmax 약간 평탄화 → α로 보정
- `α(N) = 1 + c × √(ln N)`

D=64: 소프트닝 (A < 1)

- SQNR 낮음 → 노이즈가 순위 뒤집음
- 샤프닝하면 잘못된 답에 올인
- `α(N) = SQNR / (SQNR + √(ln N / ln N₀))`

타입	SQNR	A(N=10)	A(N=2048)	A(N=131K)
TBQP3 _2/_3	3.45	0.863	**0.775**	0.735
TBQ3 _2/_3	7.80	0.934	**0.886**	0.863
TBQ4 _2/_3	14.05	0.963	**0.934**	0.919

K vs V 분리 실험 검증

K	V	파울리 테스트	결론
f16	f16	✅ **완벽**	기준
f16	tbq3_2	✅ **완벽**	**V는 문제 아님**
tbqp3_3	f16	❌ **루프**	**K가 병목**
tbqp3_3	tbq3_2	❌ **루프**	K 노이즈 확인
tbq3_3	tbq3_2	✅ **통과!**	**QJL 제거 = 해결**

결론: V는 3비트로 충분. K에서 QJL을 빼고 순수 3비트 Lloyd-Max를 쓰면 head_dim=64에서도 동작.

TBQP3 vs TBQ3 K 스코어 품질 수학

타입	구조	SCORE SQNR (D=64)	노이즈/시그널
TBQ3	3-bit Lloyd-Max (8 centroid)	**7.8**	**35.8%**
TBQP3	2-bit MSE + 1-bit QJL	**3.45**	**53.8%**

핵심: QJL의 1-bit 랜덤 프로젝션은 K reconstruction MSE를 줄이지만 attention score에 **두 번째 노이즈 소스**를 추가. D=256에서는 무시 가능하지만 D=64에서는 signal gap(~1.0)을 초과(1.67). TBQ3로 3비트 전부 centroid에 투자하면 max noise=1.11로 gap 이내.

최종 결과 달성

- tbq4/tbqp4 D=512: WHT 도메인 불일치 수정, 수학벤치 20/35 = f16 동점
- head_dim=64 cross-head: per-head RMS norm으로 양자화 품질 복원
- K QJL 노이즈 발견: tbqp3 → tbq3 자동 전환으로 SQNR 2.3배 향상
- MMSE 동적 소프트닝: D≥256 샤프닝 / D=64 소프트닝 이론 통합
- GPT OSS 120B (head_dim=64) 파울리 테스트 **통과**
- 릴리즈 워크플로우 수정 (master→main, 아키텍처별 빌드)

D=64
cross-head 동작

2.3x
SQNR 향상 (QJL 제거)

α<1
MMSE 소프트닝

PASS

파울리 테스트

Speaker notes