TurboQuant v1.6.0

Polar Derotate + Tangent Residual 수학 브레이크스루

2026-04-14 ~ 04-15 | Qwen3-14B | TBQX3_1 · 3.625 bpw

Math +20% vs f16 | 4.74x 압축 | v1.6.0 릴리즈 | AmesianX

세션 개요

목표

Coupled-RoPE K 캐시 polar derotate end-to-end 구현.
3 bpw 로 f16 품질 달성.

결과

TBQX3_1 **3.625 bpw · 4.74x 압축**.
Qwen3-14B 수학 벤치 **f16 이김** (37.1% vs 34.3%).

수학 돌파구

Tangent Residual — "잔차는 접선 방향" 한 줄 통찰.
4.25 bpw Direct Signs → 3.625 bpw 로 압축.

하드웨어 수수께끼

DGX Spark 무음 프리즈 원인 **85°C 열 차단** 확정.
소프트웨어 가설 전부 red herring.

TBQX3_1 블록 구조 3.625 bpw

Pre-RoPE (polar) 도메인에 저장 + 재회전 시 복원. RoPE 결합을 양자화 전에 분리.

필드	크기	역할
`d_r`	2 B	Rayleigh σ 추정 (블록당 스케일)
`qr[24]`	24 B	3-bit Rayleigh Lloyd-Max r 인덱스 (64 페어)
`qphi[24]`	24 B	4-bit uniform φ 인덱스 (각도 π/8 해상도)
`qtan[8]`	8 B	**1-bit tangent residual** (NEW) · φ 오차 ±π/16

수정 파일 13개: ggml.h, ggml-common.h, cpy-utils.cuh, fattn-common.cuh, fattn-vec.cuh, set-rows.cu, fattn.cu, ggml-cuda.cu, ggml.c, arg.cpp, common.cpp, CMakeLists, 새 template instance

🔑 Tangent Residual 수학 브레이크스루

관찰: Rayleigh Lloyd-Max 이후 잔차 오차가 거의 전부 접선 방향 `(-sin φ, cos φ)` 에 위치

해석적 크기

`r · π/16` — 3비트 셀의 반폭.
블록별 메타데이터 불필요.

방향 무료

디퀀트가 이미 계산한 `cos/sin` 좌표 치환으로 얻음.

비용

페어당 **1 bit** (qtan[8]) + 읽기 FMA 2개.

효과

φ 오차 ±π/8 → **±π/16** (22.5° → 11.25°).

폐기된 변종 3종 제거

변종	BPW	폐기 사유
TBQXP3_1	4.25	Direct Signs residual. **Tangent Residual 이 1 bit 만에 같은 품질** 달성해서 과지불로 판정. 제거.
TBQX2_1	2.625	2-bit quadrant angle. π/2 해상도는 attention top-1 마진 아래. Qwen3-14B가 "Hangul" 반복만 출력. 제거.
WHT + Polar	—	Per-cell Q WHT 비용 **10배 증가**. Tangent Residual 이 같은 drift 문제 값싸게 해결. 포기.

폴라 vs WHT 결합 불가 교훈: polar = 각도 구조 보존 (수학 reasoning), WHT = outlier dispersion (산문). 다른 영역 최적화.

Math Bench 결과

Qwen3-14B · seed 1234

CONFIG	KV BUFFER	T/S	MATH /35	압축비
f16 / f16	6400 MiB	24–25	12 (34.3%)	1.00x
tbqx3 / tbq3	**1350 MiB**	21–22	13 (37.1%)	**4.74x**
tbq3 / tbq3	1250 MiB	21–22	10 (28.6%)	5.12x

다중 seed 평균: tbqx3 **vs f16 약 +20%**, vs tbq3 약 +35%. seed 52는 무승부.
키릴문자 drift 완치: Pauli/Schrödinger 음차 질의에서 섞임 현상 → 순수 한국어.

Pauli 음차 테스트 정성 검증

- **f16 / f16:** "바울리" — 모델 한계 (한국어만)
- **tbqx3 / tbq3 (순수):** "와оль프강 폴리" — **키릴 drift**
- **tbqx3 / tbq3 + tangent:** "와인하르트 폴리" — drift 제거, 여전히 모델 한계

> **결론:** Pauli 테스트는 결국 모델 한계 문제라 양자화 품질 평가 지표로 부적합. 이후 수학 벤치 위주로 전환.

DGX Spark 무음 프리즈 해결 하드웨어

이전 세션 가설 **전부 red herring**: build_rope_shift / set_rows local memory / memdesc 고갈

실제 원인

GB10 SoC 85°C 펌웨어 강제 차단.

소프트웨어에 전혀 보이지 않는 무음 freeze.

해결

하드웨어 전압 감소 → steady-state **70°C 초반** 유지.

교훈: 무음 하드웨어 실패는 일급 실패 모드. 소프트웨어 이등분 전에 **온도부터 체크**.

논문 업데이트 EN + KO

- **Rayleigh Lloyd-Max 서브섹션** 신규 — 해석적 유도 + σ 추정
- **Tangent Residual 서브섹션** 신규 — 수학 유도 + 그림
- **Evaluation:** Phase 1-4 계획 → 실측 결과 테이블 3개
- **Research Roadmap: Dead Ends 섹션** — TBQXP3_1 / TBQX2_1 / WHT+polar / calibration / thermal
- **타이포그래피:** pdflatex → `xelatex + fontspec(TeX Gyre Termes) + microtype + xeCJK/kotex`
- **한국어판 재작성** — 영어 직역체 제거, 자연스러운 한국어로
- PDF **12 pages (EN), 10 pages (KO)**, README 4종에 링크

Issue #19 대응 실존적 공격

cutlerbenjamin1-cmd 공격: "TBQ 전변종이 q4_0 에게 self-cosine / Spearman / top-5 loss, 30-70% 느림"

답변 기조

- q4_0 경쟁 정면 인정
- evaluation coverage gap 자인
- harness 공유 요청
- v1.6.0 TBQX3_1 재측정 요청

기술 정정

- QJL 진단 수정 (tbq_signs 하드코딩, tbq4_1 는 QJL 없음)
- v1.5.2 half2→float fix 유지 확인
- head_dim 128 only verified, 256/512 미검증

릴리즈 CI 워크플로우 fix 최종 해결

증상: libggml-cuda.so undefined reference to `cuMemMap`, `cuMemCreate`, `cuDeviceGet`...
원인: nvidia/cuda devel 이미지에서 libcuda stub 이 표준 경로 밖 (`/usr/local/cuda/lib64/stubs/`)

- **1차 시도 (실패):** `CMAKE_EXE_LINKER_FLAGS="-L/stubs -Wl,-rpath-link,/stubs"` — DT_NEEDED 없으면 rpath-link 의미 없음
- **2차 시도 (성공):** 도커 스크립트에 `ln -sf /stubs/libcuda.so /usr/lib/libcuda.so.1` — CMake find_library + ld 자동 발견

결과: run #24422871815 에서 **Windows 6 + Linux 5 + aarch64 전부 성공**, v1.6.0 릴리즈에 **12개 바이너리** 업로드 완료.

커밋 요약 9 commits

해시	내용
`c7ba61d46`	feat(tbqx3): tangent residual correction + 실패 변종 제거
`1e84ec35a`	docs(paper): Polar Derotate paper EN/KO + README links
`2e3c26c73`	docs(paper): fix PDF typography (fontspec + microtype + table*)
`46b93143a`	docs(paper): fix column overflow (Rayleigh, verbatim, tangent eq)
`2fb6c5cd6`	chore(paper): remove tracked intermediates, add .gitignore
`b7aaf0086`	docs(readme): note TBQX3_1 is VEC-only, MMA port pending
`9c54860fe`	docs(paper-ko): soften stiff Korean prose
`97a199fd0`	ci(linux): symlink libcuda stub (최종 해결)

핵심 교훈 retrospective

- **수학적 브레이크스루는 간단하다** — Tangent Residual 은 "잔차가 접선 방향에만 존재" 한 문장. 한 줄 통찰이 4.25 bpw → 3.625 bpw
- **실패한 연구도 기록 가치 있음** — 5가지 dead end + thermal 에피소드가 설계 공간을 좁혀줌
- **무음 하드웨어 실패는 일급 실패 모드** — 소프트웨어 이등분 전에 온도부터 체크
- **polar vs tbq는 다른 영역 최적화** — polar = 각도 (수학), tbq-WHT = outlier (산문). 결합 불가 (per-cell WHT 10x 비용)
- **논문은 쓰고도 덮기** — 영어 직역체 한국어는 안 됨. 자연스러운 어순으로 재작성

다음 작업

TBQX3_1 MMA 포팅

현재 vec only 0.87x f16. MMA 로 옮기면 전속도 회복. **최우선**.

Q4_0 직접 벤치

Issue #19 제기 사항. 프로젝트 존재 이유 검증.

HEAD_DIM 결정성

256/512 미검증. V_DOT2 undef + set_rows σ reduction 점검.

CI 결정성 REGRESSION

자동 테스트 추가 (Issue #19 제안).

PPL ERROR BAR 재측정

error bar 포함해서 다시.

UPSTREAM REBASE

24 커밋 밀림. FA 쪽 변경 있어 충돌 가능.