TriAttention 통합

AMX3_1 하이브리드 K 캐시 × pre-RoPE polar 스코어링 × 물리 eviction

2026-04-20 ~ 04-21 | Qwen3-14B Q4_K_M | AMX3_1 · 6.75 bpw

Needle Test 성공 | 20 tok/s 유지 | 95% eviction 품질 유지 | AmesianX

세션 개요

목표

TriAttention 논문 (Mao et al., arxiv 2604.04921) 포팅.
Pre-RoPE polar 스코어링으로 dequant-free KV eviction.

결과

End-to-end 동작 + **needle test 성공**.
"비밀번호 다람쥐7429" 정확 회수. 반복 루프 해소.

기술 혁신

AMX3_1 Part B (polar) **직접 소비**.
GPU→CPU 전송 없는 스코어링.

성능

Prompt 694 tok/s, **Eval 20.7 tok/s**.
오버헤드 무시 수준 (기준선 f16과 동일).

AMX3_1 하이브리드 블록 구조 108B · 6.75 bpw

TriAttention 을 위한 이중 인코딩: WHT 경로(FA attention)와 polar 경로(스코어링) 병행.

PART	크기	필드	역할
Part A WHT	2 B	`d_wht`	WHT 도메인 L2 norm (FA 디코더가 사용)
	48 B	`qs[48]`	3-bit Lloyd-Max (tbq3_1 동치, 128 elements)
Part B Polar	2 B	`d_r`	Rayleigh σ (polar 스케일)
	24 B	`qr[24]`	3-bit Rayleigh r 인덱스 (64 페어)
	32 B	`qphi[32]`	4-bit uniform ϕ 인덱스

Part B → pre-RoPE (kxc, kyc) 직접 복원 → TriAttention 스코어링에 사용. 50% 유지 시 effective 3.375 bpw.

3-Kernel 스코어링 파이프라인

1. RAW SCORE

grid=(n_kv, num_heads)
block=fc (thread/pair)
Part B 복원 + 17 offset sincosf 합 + block reduce

2. Z-NORMALIZE

grid=num_heads, block=256
head별 mean/std 계산
in-place 정규화

3. AGGREGATE

grid=(n_kv/T), block=128
per-slot max across all heads
→ out_scores[n_kv]

스코어링 공식: `S_trig = Σ rel_r·cos(Δ·ω) - rel_i·sin(Δ·ω)` (17 geometric Δ, 64 freq) + `S_norm = max(0, qam-qma) · r`

물리 eviction + attention sink

HISTOGRAM THRESHOLD

1024-bin 히스토그램 기반 K번째 largest. Single-thread kernel. n_kv=2500 기준 ~5µs.

MASK KERNEL

병렬 `score ≥ threshold ? 1 : 0` 비교.

ATTENTION SINK (C2)

`mask[0..keep_first] = 1` 강제 override.
BOS + 프롬프트 헤더 보호.

PHYSICAL EVICTION (C1)

mask=0 슬롯에 `d_wht=0` **AND** `d_r=0`.
재스코어링 시 0점 → 영구 제외.

Needle Test 검증 성공

프롬프트: "비밀번호는 **다람쥐7429** 이다. [양자역학 요약 요청] ... 요약 마지막에 비밀번호 정확히 적어라."

버전	토큰	종료	비밀번호	현상
초기 (버그 상태)	2500	length	❌ 언급 없음	"다름, 다름, 다름..." 폭주
keep_first=4	575	stop	❌ "다섯"	반복 해소, 회상 실패
keep_first=32	**366**	stop	✅ "다람쥐7429"	정답 회수 + 자연 종료

프롬프트 앞 32 토큰 보호 → 비밀번호 "다람쥐7429" 생성 끝(position 366)까지 살아남음.

CLI 플래그 + API

플래그	기본값	의미
`--triattention <FILE>`	—	TRIA v2 칼리브레이션 파일
`--tri-budget N`	0 (비활성)	레이어별 Top-B 예산
`--tri-interval N`	128	트리거 토큰 간격 (논문 β)
`--tri-keep-first N`	4	Attention sink — 앞 N 슬롯 강제 유지

공개 C API: `llama_tria_load() / llama_tria_free() / llama_tria_attach()`

내부 3단 API: `tria_trigger_prepare → tria_trigger_score_layer → tria_trigger_finish`

해결한 Critical 버그 5종

ID	버그	증상 / 원인 / 해결
C1	Eviction 후 Part B 방치	d_wht만 0 세팅 → 재스코어링에서 재선택 → 반복 루프 폭주. d_r도 0 으로 영구 제외.
C2	Attention sink 누락	softmax 질량 배출구 없음 → "다름, 다름..." 폭주. `keep_first` 파라미터 추가.
B1	kept = n_kv 전체	`v_cells.size()=40960` 그대로 넘김 → 빈 슬롯까지 스코어 → 히스토그램 왜곡. `n_valid` 사용.
B2	n_stream>1 미가드	멀티 시퀀스 모드 미지원 가드 추가.
—	Private member access	llama_context 필드 private 섹션에 들어가 compile 실패. public setter `tria_set()` 경유.

뻘짓 히스토리 (1/2) retrospective

- **Qwen3.6-35B 40분 허비** — head_dim=256 (config에 있었음), AMX3_1 호환 불가. Qwen3-14B 로 재칼리브레이션.
- **llama.h include 지옥** — ggml-cuda에 `#include "llama.h"` 경로 없음. extern "C" 전방선언만으로 해결.
- **private 필드 실수** — llama_context 멤버가 private 섹션. free function 접근 불가. public setter 추가.
- **kept=40960 분석 오해** — "레이어간 일관성 너무 높다" 라고 착각. 실제론 로그 필터 부작용.
- **transformers 4.57.3 → 5.5.4** — qwen3_5_moe 미지원 버전. 업그레이드 필요했음.
- **wikitext 경로 헤매기** — `~/llama.cpp/wikitext-2-raw/` 아닌 `~/work/cuda_research/wiki.test.raw`.
- **서버 바이너리 구버전 실행** — `make -j` 가 링크 보장 안 함. `--target llama-server` 또는 clean build 필요.
- **Dead code 3종 방치** — `tria_head_stats_dev`, `llama_tria_stats_unwrap`, `tria_wrapper_layer_scales_ref` 감사 단계에서 제거.

뻘짓 히스토리 (2/2) retrospective

- **API 시그니처 3회 변경** — 단일 함수 → keep_first 추가 → 3단 분할 (prepare/score/finish). 매번 호출부 + 전방선언 동시 갱신.
- **const_cast 지옥** — `const void * K_cache_gpu` 시그니처에 쓰기 필요. 감사에서 `void *` 로 정리.
- **cur_pos 3회 변경** — max 루프 → `host_pos[n_valid-1]` → 방어용 max 복원 → 사용자 지적으로 다시 간결화 (feedback_no_fallbacks 위반).
- **Log spam** — 40 레이어 × 트리거당 1줄 = 2500 토큰 시 780줄. aggregate + `TRIA_VERBOSE=1` 로 개선.
- **Threshold 커널 단일 스레드 패스** — SM 이용률 1/32 이하. n_kv=2500에서 ~5μs 병목 아니라 후순위.
- **"초최최최종" 리뷰 4회** — 매번 새 발견. self-review 한계 실감.

최종 감사 수정사항

CRITICAL (C1/C2)

Eviction 영구성 (d_wht + d_r 모두 zero)
Attention sink (`--tri-keep-first`)

HIGH (H1~H3)

tria_load `goto cleanup` 패턴
scratch_ensure 할당 실패 전체 해제
scratch_free 전 stream sync

MEDIUM (M1/M5)

3단 API 분할 (position H2D 1회)
Aggregate log + `TRIA_VERBOSE` env

ARCHITECTURE (A3)

Per-layer budget scale 적용
`budget * layer_scales[il]`

FINAL (F1~F3)

prepare 시 state 선제 리셋
finish 시 항상 리셋
layer_scales D2H 에러 로깅

CLEANUP (B1~B4/S1)

n_stream 가드
const_cast 제거
Per-layer AMX3_1 type 체크

성능 측정 Qwen3-14B Q4_K_M · AMX3_1

항목	값	기준선 F16	비고
Prompt	**694 tok/s**	~700	거의 동일
Eval	**20.7 tok/s**	~21	오버헤드 무시
트리거당 오버헤드	~120 ms	—	40 layer × ~3 ms
128 토큰 생성 대비	~2%	—	6.4 s 중 120 ms
실효 kept / n_kv	~130 / 2500	2500	95% eviction

결론: 95% eviction 상태에서도 품질 유지 + 속도 손실 없음. TriAttention 논문 주장 실증.

핵심 교훈

- **모델 config의 key_length/value_length를 먼저 확인** — hidden/num_heads는 Q 기준, K 저장은 다를 수 있음 (gated attention, partial rotary)
- **Eviction 영구성은 Part A + Part B 모두 zeroing** — 점수 경로(Part B)를 그대로 두면 재선택됨
- **Attention sink는 필수** — softmax 붕괴는 즉시 생성 품질 파괴 (무한 반복)
- **API는 처음부터 3단 설계** — 리소스 업로드/재사용/정리 분리가 자연스럽다. 단일 함수로 시작하면 리팩토링 비용 큼
- `make -j` **는 target 종속성 자동 포함 안 됨** — 바이너리까지 재링크하려면 명시적 target 지정
- **감사는 반복해도 새 발견** — self-review 본질적 한계. 시간 간격 + 다른 관점 = 최선
- **피드백 메모리 실제 작동** — "No Fallbacks" 를 감사 중 위반했다가 사용자가 직접 지적해 원복

다음 작업

스트레스 테스트

4000+ 토큰 생성, n_kv>10000 안정성. **내일 예정**.

수학 벤치

MMLU/GSM8K 정밀도 영향 측정.

다른 모델 범용성

head_dim=128 모델들 (Qwen3-30B-A3B 등).

BUDGET 하이퍼 스윕

64/256/512 품질-성능 곡선.

THRESHOLD 병렬화

단일 스레드 → 병렬 reduction.

TBQ ATTN_ROT_K 재설계

외부 회전 의존 제거. 별도 세션.